

中国图书分类号 TP391;TP311

密级 公开

国际图书分类号 004

单位代码 10613

西南交通大学

硕士学位论文

面向政务领域的大模型数据查询与分析方 法研究与实现

学科专业 计算机科学与技术

学 号 2023201808

作者姓名 陈鑫海

指导教师 郑宇教授

学 院 计算机与人工智能学院

2026 年 3 月 20 日

A Thesis Submitted to
Southwest Jiaotong University for Master Degree

**Research and Implementation of Data Query and
Analysis Methods Based on Large Language Models
for the Government Affairs Domain**

Discipline Computer Science and
Technology

Student ID 2023201808

Author Chen Xinhai

Supervisor Professor Yu Zheng

School School of Computing and
Artificial Intelligence

March. 4, 2026

西南交通大学

学位论文独创性声明

本人郑重声明：所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得西南交通大学或其它教育机构的学位或证书而使用过的材料。其他人员对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

本学位论文的主要创新点如下：

作者签名：_____

日期： 年 月 日

西南交通大学

学位论文使用授权

本学位论文作者完全了解西南交通大学有关保留、使用学位论文的规定，同意学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅。本人授权西南交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索及下载，可以采用影印、缩印、扫描等复制手段保存、汇编本学位论文。

本学位论文属于

1. 保密□，在 年解密后适用本授权书
2. 不保密□，使用本授权书。

(请在以上方框内打“√”)

作者签名：_____ 导师签名：_____

日期： 年 月 日

摘 要

这里是中文摘要输入区。

关键词：关键词 1，关键词 2，关键词 3，关键词 4，关键词 5

Abstract

Here is for you to write the English abstract.

Keywords: keyword1, keyword2, keyword3, keyword4, keyword5

目 录

第 1 章 绪论	1
1.1 研究背景与意义	1
1.1.1 研究背景	1
1.1.2 研究意义	2
1.2 国内外研究现状	3
1.2.1 基于大模型的 Text-to-SQL 研究现状	3
1.2.2 基于大模型的代码生成与自动数据分析研究现状	5
1.2.3 政务数据管理与应用平台研究现状	5
1.2.4 现有研究评述	6
1.3 论文研究内容	8
1.4 论文章节安排	9
1.5 本章小结	9
第 2 章 相关理论与技术	11
2.1 大语言模型与工具增强基础	11
2.1.1 Transformer 与指令对齐	11
2.1.2 上下文学习、链式推理与结构化输出	12
2.1.3 工具调用与代码执行	12
2.2 面向可靠查询生成的关键技术	13
2.2.1 任务定义与核心挑战	13
2.2.2 Schema/值检索与领域知识增强	14
2.2.3 候选生成、执行反馈与结果选择	14
2.3 面向数据分析的规划与结果生成技术	15
2.3.1 分析任务链条与中间规划	15
2.3.2 代码生成、分析算子与可视化组织	16
2.3.3 查询与分析分层协同	16
2.4 面向系统实现的工作流编排与服务协同	17
2.4.1 工作流图编排、状态管理与异常回传	17
2.4.2 轻量级 Agent 协同与角色分工	17
2.5 本章小结	18
第 3 章 基于逻辑增强与异构协同的政务数据查询生成方法	19

3.1	引言	19
3.2	总体框架设计	20
3.3	离线知识准备	21
3.3.1	向量库构建	21
3.3.2	政务领域知识库构建	22
3.3.3	动态样例库构建	23
3.4	基于逻辑增强的模式链接	25
3.5	异构候选生成	28
3.5.1	逻辑映射生成器	28
3.5.2	渐进分治生成器	29
3.6	基于执行反馈的查询修复	30
3.7	候选判别模型	32
3.7.1	训练样本构建	33
3.7.2	判别模型训练	33
3.7.3	配对判别与最优候选选择	34
3.8	实验与结果分析	35
3.8.1	数据集构建与实验设置	35
3.8.2	评估指标与对比基线	36
3.8.3	总体性能对比	37
3.8.4	消融实验	38
3.8.5	异构协同与候选判别分析	39
3.8.6	效率分析	41
3.8.7	公共数据集实验结果	42
3.9	本章小结	44
第 4 章	基于分析规划与查询增强的政务数据分析方法	45
4.1	引言	45
4.2	总体框架设计	46
4.3	分析规划构建	48
4.3.1	规划模式定义	48
4.3.2	约束与完备性	49
4.3.3	规划生成	50
4.4	基于查询增强的分析任务分解方法	52
4.4.1	查询层与分析层的任务划分	52

4.4.2 任务分解准则与层级判定	53
4.4.3 查询结果表示与层间衔接	54
4.5 基于分析算子的结果生成方法	55
4.5.1 分析算子设计与编排	55
4.5.2 结果生成流程与输出组织	56
4.6 实验与结果分析	58
4.6.1 实验设置与评价指标	58
4.6.2 结果对比	60
4.6.3 分类型性能对比	60
4.6.4 模块消融实验	61
4.6.5 AP-Schema 规划质量评估	63
4.7 本章小结	63
第 5 章 政务智能问数系统设计与实现	65
5.1 引言	65
5.2 系统总体架构	65
5.3 应用层与智能服务层实现	66
5.3.1 应用层接口设计	66
5.3.2 任务状态管理与异常回传	68
5.4 系统数据层存储	69
5.4.1 业务数据源接入与元数据抽取	69
5.4.2 系统元数据库实现	70
5.4.3 结果、日志与缓存管理	71
5.5 系统功能实现与效果展示	72
5.6 本章小结	75
结论与展望	76
致 谢	77
参考文献	78
附录 A	85
攻读硕士学位期间取得的研究成果	87

第 1 章 绪论

1.1 研究背景与意义

1.1.1 研究背景

从应用场景看，数字政府建设正在持续推动政务数据资源沉淀，并使数据逐步成为政府治理的重要生产要素。2022 年，国务院印发《关于加强数字政府建设的指导意见》，明确提出以数据资源开发利用贯通政府管理、公共服务和科学决策各环节，充分释放数据要素价值^[1]。2023 年，中共中央、国务院印发《数字中国建设整体布局规划》，进一步将数字政府和数据资源体系建设上升为国家战略部署^[2]。2025 年，国家发展改革委、国家数据局、工业和信息化部联合印发《国家数据基础设施建设指引》，从数据流通利用、算力底座、网络支撑和安全防护等方面提出总体建设方向，强调以基础设施能力支撑数据高效流通与应用开发^[3]。在上述政策持续推动下，各级政府部门不断推进数据归集、治理与共享交换，财政预算、公共资源、社会治理、经济运行等场景积累了大量结构化政务数据，政务数据已经成为支撑政府业务协同、治理监测和科学决策的重要基础^[4-5]。

从应用瓶颈看，政务数据规模的快速增长并未自然转化为高效的数据使用能力。当前政务数据应用仍主要依赖两种模式：一是由技术人员编写 SQL 语句完成数据库查询，再由业务人员进行人工解读和汇总；二是通过预置报表和 BI 看板查看固定口径的统计结果。前者对使用者的数据库知识、统计分析能力和业务理解能力要求较高，难以支撑非技术岗位开展自主问数；后者虽然降低了操作门槛，但通常只能提供预定义维度下的静态展示，难以满足临时性、多维度和深层次的数据探索需求^[4-5]。与此同时，政务任务普遍具有跨部门、跨层级和跨区域协同特征，围绕协同治理形成的数据又呈现出显著的时空性、层级性和业务约束性。已有研究表明，面向政府大规模协同任务的数据管理与统计分析本身就具有较高复杂度，传统离线处理和割裂式系统难以及时响应复杂场景下的动态分析需求^[6-7]。这使得政务数据应用长期面临“数据可得但难用、报表可看但难析、需求可提但响应滞后”的现实困境。

从技术现状看，近年来以 GPT-4^[8]、Qwen^[9]和DeepSeek^[10]为代表的大语言模型在自然语言理解、代码生成、复杂推理和工具调用等方面表现出显著提升^[11]，推动自然语言问数、自动代码生成和自动数据分析等方向快速发展。在数据查询层面，Text-to-SQL 技术已能够将自然语言问题自动转换为结构化查询语

图示占位：政务数据应用面临的挑战与智能问数带来的机遇

左侧展示政务数据应用中的主要挑战：数据来源分散、业务术语复杂、技术门槛较高、协同链路较长、分析反馈滞后。

中间展示驱动因素：数字政府建设持续推进、政务数据持续沉淀、大语言模型能力快速提升。

右侧展示智能问数带来的机遇：自然语言交互、自动查询生成、自动分析与可视化、结果追溯与决策支持。

图 1-1 政务数据应用面临的挑战与智能问数带来的机遇示意图

句^[12]；在数据分析层面，大语言模型结合代码执行和分析规划能力，开始具备围绕数据结果生成图表、表格和分析结论的潜力^[13-14]。从国内应用看，大语言模型已逐步进入交通、民生服务和政务服务等垂直领域，基于自然语言交互的智能问数模式正从概念验证走向场景化探索^[15-17]。但政务场景中的数据语义、统计口径和结果规范性要求显著高于通用商业场景，直接迁移通用方法往往仍面临领域知识融入不足、分析流程缺乏结构化约束、查询与分析环节协同不畅等问题。

基于上述场景、瓶颈和技术现状，本文聚焦于政务领域智能问数与数据分析这一研究主题，关注的问题不是单一的“自然语言转 SQL”，而是如何围绕政务业务语义构建一条从自然语言需求理解、可靠查询生成、规范分析执行到系统交互落地的完整技术链路。概括而言，本文的研究目标是面向政务场景，构建“可靠查询 + 规范分析 + 系统落地”的一体化智能问数方法体系，使非技术人员也能够基于自然语言完成问数、查数和分析数。围绕这一目标，本文需要依次回答三个关键问题：第一，如何提升面向复杂政务业务逻辑的 Text-to-SQL 生成准确性与稳定性；第二，如何将开放式分析需求转化为结构化分析规划，并在可靠取数基础上完成规范化分析生成；第三，如何将上述方法组织为可交互、可追溯、可落地的政务智能问数系统。

1.1.2 研究意义

本文的研究兼具理论意义与实践意义。

理论意义。（1）推动领域知识增强的 Text-to-SQL 方法研究。现有 Text-to-SQL 方法多在 Spider^[18]、BIRD^[19]等通用数据集上验证，虽然在通用场景中取得显著进展，但对于政务场景中普遍存在的业务术语歧义、字段缩写复杂和隐含计算逻辑等问题仍支持不足^[12,20]。本文通过逻辑增强模式和政务领域知识库的结合，探索将领域先验知识显式注入模式表示与生成流程的实现路径，为垂直领域 Text-to-SQL

方法研究提供参考。

(2) 探索查询生成与数据分析的结构化协同方法。现有研究通常将“查询生成”和“分析生成”分别建模,缺少统一的中间表示来描述分析需求、查询约束和结果组织之间的关系^[14]。本文通过构建分析规划模式 AP-Schema,将自然语言分析需求映射为结构化规划,并通过查询增强机制建立查询层与分析层之间的协同关系,为“先查准、再分析”的层级协同提供方法基础。

(3) 丰富面向政务场景的智能数据分析研究。政务数据分析不仅要求结果正确,还要求分析口径清晰、结果展示规范、结论表达可追溯。本文围绕趋势分析、对比分析、排名分析和结构分析四类典型政务分析任务设计分析算子链和结果组织方式,有助于拓展大语言模型与自动数据分析技术在政务场景中的研究边界^[13,21]。

实践意义。(1) 降低政务数据使用门槛。通过自然语言交互替代传统的 SQL 编写和复杂报表配置,可使行政管理、政策研究和业务监督等岗位的非技术人员直接表达数据需求,缩短“提出需求—等待开发—返回结果”的协作链路,提高政务数据使用的实时性与自主性。

(2) 提升治理决策中的数据支撑深度。相较于仅返回原始查询结果,本文研究的智能问数方法进一步覆盖数据分析、图表生成和洞察摘要等过程,可将政务数据应用从“取到数”延展到“看懂数、用好数”,从而为经济运行监测、财政绩效评估、公共资源配置和协同治理等场景提供更深入的数据支撑。

1.2 国内外研究现状

围绕本文研究主题,现有相关工作主要可归纳为三个方向:基于大模型的 Text-to-SQL 研究、基于大模型的代码生成与自动数据分析研究,以及政务数据管理与应用平台研究。三类研究分别对应“如何查到正确数据”“如何围绕数据形成规范分析结果”“如何在政务场景中组织和落地数据应用”三个层面。因而,本节不仅梳理已有工作的进展与优势,也进一步识别其在政务场景中的能力边界,以说明本文研究的必要性与切入点。

1.2.1 基于大模型的 Text-to-SQL 研究现状

Text-to-SQL 旨在将自然语言问题自动转换为可在关系数据库上执行的结构化查询语句,是自然语言数据库接口的重要研究方向^[12]。从技术演进看,该领域大致经历了基于规则与模板的方法、基于深度学习的端到端方法、基于预训练模型的方法,以及当前基于大语言模型的方法四个阶段^[12,20]。

早期研究主要依赖人工设计语法规则、模板库和领域词典,在特定领域或小

规模数据库上可获得较高精度，但其知识获取成本高、迁移能力弱，难以适应复杂多变的跨库场景。随后，Seq2SQL^[22]、SyntaxSQLNet^[23]等方法将 Text-to-SQL 建模为序列生成问题，推动研究从显式规则构造转向数据驱动的语义映射。该阶段显著提升了模型对自然语言查询的泛化能力，但在复杂嵌套查询、模式链接和跨域迁移方面仍存在明显不足。

在预训练模型阶段，研究重点进一步转向“问题语义表示与数据库模式结构建模”的深度融合。RAT-SQL^[24]通过关系感知编码器强化问题与 Schema 的细粒度对齐，BRIDGE^[25]引入数据库内容锚定缓解字段匹配歧义，PICARD^[26]通过增量语法约束降低了解码过程中的语法错误率，RESDSQL^[27]则通过解耦 Schema 链接与 SQL 骨架生成提升整体鲁棒性。这一阶段奠定了“语义表示 + 结构感知 + 约束生成”的主流范式。

进入大语言模型阶段后，Text-to-SQL 研究进一步借助上下文学习和强生成能力形成两条主流路线。一类是基于指令微调的专用模型路线，强调利用大规模训练数据和领域适配提高模型的数据库理解与 SQL 生成能力；另一类是基于提示工程的上下文学习路线，通过组织任务指令、模式描述、示例和约束信息，直接引导通用大模型生成 SQL^[20,28]。代表性工作中，DAIL-SQL^[29]系统优化了问题表示、示例选择和示例组织策略，DIN-SQL^[30]通过任务分解降低单次提示复杂度，在复杂查询场景中取得较好效果。

进一步地，近期研究开始从多路径生成、候选集构造和结果选择等角度提升复杂查询的准确率与稳定性。CHASE-SQL^[31]采用多路径并行生成与选择模型结合的方式提升最终结果质量；XiYan-SQL^[32]通过多生成器协同构造候选集并进行集成判别；OpenSearch-SQL^[33]在动态示例检索和一致性对齐方面进行了优化；Alpha-SQL^[34]将 SQL 生成建模为搜索问题；OmniSQL^[35]通过高质量合成数据增强模型的 SQL 生成能力；CHESS^[36]和CodeS^[37]则分别从上下文组织和专用开源模型构建角度推动了该领域发展。

总体来看，现有 Text-to-SQL 研究已经显著提升了通用场景中的自然语言问库能力，但面向政务场景仍存在三方面不足。第一，政务数据库中字段名常以缩写、代码或历史系统命名方式存在，业务术语与物理字段之间存在多对多映射关系，通用 Schema 链接方法难以准确建立语义对齐。第二，预算执行率、同比增长率、结构占比等核心政务指标往往依赖隐含统计口径和计算逻辑，而这些逻辑通常不在原始 Schema 中显式表达，单纯依赖模型隐式推理容易产生“语法正确、业务错误”的结果。第三，政务问数既包含大量高频标准需求，也包含低频但复杂的长尾需求，单一生成策略较难同时兼顾生成效率与复杂查询准确性。上述不足构成了本

文第三章需要重点解决的问题。

1.2.2 基于大模型的代码生成与自动数据分析研究现状

相较于 Text-to-SQL 主要解决“如何获得正确数据”，自动数据分析更关注“如何围绕数据组织分析过程并生成可理解结果”。近年来，大语言模型在代码生成和工具调用方面的能力提升，为 Text-to-Analysis 研究提供了新的技术基础^[14]。

在代码生成方面，Codex^[38]验证了在大规模代码语料上训练的语言模型可以根据自然语言描述生成高质量程序；此后，以 Code Llama、StarCoder 和 WizardCoder 为代表的开源代码模型持续提升了代码补全、脚本生成和复杂编程任务求解能力^[39-41]。上述能力使大语言模型能够生成 Python、SQL 及数据处理脚本，为自动分析场景中的数据提取、统计计算和结果可视化奠定基础。

在自动数据分析框架方面，Data Interpreter^[13]通过规划与代码执行引擎结合实现端到端数据分析；InsightPilot^[21]通过分析操作序列辅助用户逐步发现数据洞察；LIDA^[42]和Chat2VIS^[43]分别从自然语言到可视化生成和对话式图表生成角度推进了自动可视化研究；TaskWeaver^[44]采用代码优先的 Agent 架构支持复杂分析任务执行；Data-Copilot^[45]、TableGPT2^[46]和ChartGPT^[47]则分别在自动化数据交互、表格理解和图表生成方面展示了大模型支持的数据分析潜力。

现有研究表明，“模型负责理解与规划、工具负责精确执行”的分析范式已经逐步成形，但其能力边界也较为清晰。其一，许多方法直接从自然语言需求端到端生成代码、图表或结论，缺少显式的中间规划表示，难以保证分析目标、指标、维度、筛选条件和展示形式之间的一致性。其二，查询生成与分析计算职责常被混合在同一流程中，分析模块在执行阶段重复承担数据库理解和 SQL 生成工作，不仅增加错误暴露面，也削弱了查询能力与分析能力的模块化复用。其三，现有自动分析研究大多面向商业报表、通用表格或开放式数据科学任务，对于政务场景中常见的趋势研判、横向比较、结构刻画、排名识别等规范化分析范式支持不足^[13-14]。因此，如何引入结构化分析规划、明确查询与分析分层并适配政务分析任务，成为本文第四章的主要切入点。

1.2.3 政务数据管理与应用平台研究现状

政务数据管理与应用平台建设经历了从信息资源整合、共享交换，到数据中台、BI 平台，再到引入大模型能力的智能化探索过程^[4-5]。在基础设施层面，各级政府已经构建起较为成熟的数据共享交换平台、主题数据库和业务协同系统，政务数据汇聚、治理和跨部门流通能力持续增强。相关研究也开始从平台型政府、智

能政务服务和政务数据治理等角度讨论如何通过数字基础设施提升政府的数据能力、业务能力和协同能力^[15,48]。

在应用层面，数据中台、专题数据库、商业智能系统和可视化看板仍是当前政务数据应用的主流形态。此类平台在统一数据口径、指标计算复用和固定场景展示方面具有明显优势，能够较好支撑例行监测、专题报送和领导驾驶舱等业务需求。然而，这类平台通常需要在建设阶段预设指标、维度、统计口径和图表形式，用户只能在既定框架内进行查看和筛选，难以针对临时性、探索性和跨主题问题开展自主问数与分析^[5,48]。

面向更复杂的政务协同场景，已有工作进一步表明，政务数据应用不仅是数据汇聚和看板展示问题，还涉及复杂任务组织、多层级协同和安全控制等工程挑战。王璐璐等在第 40 届 CCF 中国数据库学术会议上围绕政府大规模协同任务提出时空数据管理与分析研究思路，强调政务协同任务下数据统计与分析的复杂性^[6]。随后，Wang 等进一步提出面向政府大规模协同任务的系统框架，通过时空任务树和增量统计方法支持跨部门、跨层级协同执行场景下的数据聚合分析^[7]。赵大燕等则从安全治理角度提出面向政务协同的访问控制模型，说明政务协同系统在灵活接入之外还必须兼顾权限边界与数据安全^[49]。这些研究为理解政务场景的数据复杂性和系统复杂性提供了重要参考。

在大语言模型应用方面，国内近年开始探索政务大模型与垂直智能体在政务服务、知识问答、民生热线和垂类应用中的落地路径^[15,17,50-51]。总体上看，现有探索更多聚焦于政策咨询、文本理解、智能问答或单点应用增强，对“自然语言问数—可靠取数—规范分析—结果追溯”这一完整链路关注不足。换言之，政务平台建设已在数据治理和固定展示层面形成一定基础，但从“静态展示”向“智能理解与分析”的演进仍存在明显空间。

1.2.4 现有研究评述

综合上述研究可见，现有工作分别在自然语言查询、自动分析执行和政务平台建设三个方面奠定了重要基础，但仍未形成面向政务智能问数的完整方法闭环。为便于比较，表1-1对相关研究方向、代表方法、优势、局限及其与本文的关系进行归纳。

在上述研究基础上，本文认为当前仍存在三个关键研究缺口。第一，政务 Text-to-SQL 缺少领域知识显式增强机制。现有方法在通用场景下性能突出，但在政务场景中对业务术语映射、逻辑指标计算和复杂查询结构的支持仍不充分，难以稳定实现可靠取数。第二，自动数据分析缺少查询增强与结构化规划机制。现有方法

表 1-1 相关研究方向、代表方法及局限性对比

研究方向	代表方法	主要优势	主要局限	与本文关系
基于大模型的 Text-to-SQL	DAIL-SQL、CHASE-SQL、XiYan-SQL 等 ^[29,31-32]	提升 Schema 理解、跨库迁移和复杂 SQL 生成能力	领域知识显式注入不足，难处理政务术语映射、隐含口径和长尾复杂查询	对应本文第三章，面向政务场景增强可靠查询生成
自动数据分析	Data Interpreter、LIDA、TaskWeaver 等 ^[13,42,44]	支持代码驱动的数据处理、图表生成与分析自动化	缺少结构化中间规划，查询与分析职责混杂，对政务分析范式支持不足	对应本文第四章，构建分析规划与查询增强协同方法
政务数据管理与应用平台	数据共享交换平台、数据中台、BI 看板、政务大模型探索	强化数据汇聚治理和固定场景展示，支撑例行监测与业务管理	灵活分析能力不足，缺少自然语言交互和查询分析一体化落地能力	对应本文第五章，组织查询与分析方法形成可落地系统

虽然提升了分析自动化程度，但常将查询生成与分析执行混合处理，缺少可验证的中间规划表示和面向政务任务的规范化结果组织。第三，现有政务数据平台缺少从方法到系统的一体化智能问数落地。已有平台重数据治理、重统一展示，但在自然语言交互、自主探索分析、结果留痕与可追溯方面仍不足。换言之，本研究的必要性在于：只有同时解决查询正确性、分析规范性和系统协同性，政务智能问数才能真正从“可演示”走向“可应用”。

与此同时，现有研究也为本文提供了明确的技术可行性。其一，Text-to-SQL 领域已经形成从模式链接、候选生成到结果选择的较成熟技术路线，为可靠查询生成提供了基础；其二，自动数据分析研究已经证明大语言模型具备代码生成、任务规划和结果组织能力，为结构化分析生成提供了可用范式；其三，政务数据平台与协同系统研究已经在数据治理、元数据管理、权限控制和任务编排等方面积累了较强工程基础，为方法落地提供了现实载体。也就是说，本文并非从零构建全部能力，而是在已有工作的优势之上，围绕政务场景进一步推进领域知识增强、查询分析分层协同和系统集成。

上述三个研究缺口分别对应本文的三项核心工作：第三章研究面向复杂政务业务逻辑的可靠查询生成方法，第四章研究面向政务洞察任务的结构化数据分析方法，第五章研究面向政务场景的智能问数系统设计与实现。由此，本文形成了从方法创新到系统落地的完整研究链路。

1.3 论文研究内容

围绕上述研究缺口，本文以“可靠查询生成、结构化分析生成、系统落地实现”为主线，开展面向政务领域的大语言模型数据查询与分析方法研究。总体思路不是让大语言模型端到端自由生成全部结果，而是按照“先查准、再分析、后落地”的路径逐层求解：先保证查询结果可靠，再保证分析过程规范，最后将方法封装为可交互系统。本文整体研究框架与技术链路如图1-2所示。




图 1-2 本文整体研究框架与技术链路示意图

（1）**基于逻辑增强与异构协同的政务数据查询生成方法。**针对政务数据查询中业务术语语义模糊、逻辑计算隐含和复杂查询结构长尾分布等问题，本文提出一种面向政务场景的 Text-to-SQL 方法。该方法在离线阶段构建向量索引数据库、政务领域知识库和动态样例库，在在线推理阶段设计逻辑增强模式 LA-Schema，将业务术语映射、逻辑计算公式和值域约束显式注入数据库模式；同时设计逻辑映射生成器和渐进分治生成器组成的异构协同候选生成机制，并结合执行反馈驱动的查询修复和基于微调的候选判别模型，提高最终 SQL 查询的准确性、执行成功率与稳定性。该研究对应第三章，目标是解决政务场景下“查准”和“查稳”的问题。

（2）**基于分析规划与查询增强的政务数据分析方法。**针对政务分析任务中需求约束复杂、查询与分析职责耦合以及结果表达需规范化等问题，本文提出一种协同查询能力的数据分析方法。该方法首先引入分析规划模式 AP-Schema，将自然语言分析需求转化为包含分析类型、指标、维度、筛选条件、统计粒度、操作分层和可视化规格的结构化中间表示；其次，通过查询增强的任务分解机制，将涉及统计口径、模式理解和复杂关联的操作下沉至查询模块完成，而分析模块仅在可靠查询结果上执行排序、占比、透视、标注等轻量分析操作；最后结合分析算子库和可视化规则，生成图表、表格、文字洞察和日志组成的标准化结果包。该研究对

应第四章，目标是解决政务场景下“怎么分析”和“如何规范输出”的问题。

(3) 政务智能问数系统设计与实现。在前述查询方法和分析方法基础上，本文进一步设计并实现一个面向政务场景的智能问数系统。系统采用表示层、应用层、智能服务层和数据层四层架构：应用层以 FastAPI 构建统一 HTTP 入口，支持同步查询与异步分析两类调用方式；智能服务层以 LangGraph 组织查询子图和分析子图，使分析流程通过 AP-Schema 投影查询约束后复用查询能力；数据层利用 PostgreSQL 保存系统元数据和领域知识，利用 Milvus 承载向量索引，利用 Redis 支持缓存和流式事件通道，实现结果产物、执行日志和会话状态的持久化管理。该研究对应第五章，目标是将方法创新转化为可交互、可追溯和可展示的系统能力。

1.4 论文章节安排

本文共分为六章，各章内容安排如下。

第一章，绪论。阐述论文的研究背景与意义，综述国内外相关研究现状，归纳当前存在的 key 问题，并给出本文的研究内容与整体结构安排。

第二章，相关理论与技术。介绍论文所依赖的理论基础与关键技术，包括大语言模型与工具增强基础、面向可靠查询生成的关键技术、面向数据分析的规划与结果生成技术，以及面向系统实现的工作流编排与服务协同技术。

第三章，基于逻辑增强与异构协同的政务数据查询生成方法。围绕政务场景中的可靠取数问题，提出包含离线知识准备、逻辑增强模式链接、异构候选生成、执行反馈修复和候选判别选择在内的 Text-to-SQL 方法，并通过自建政务数据集和公共数据集实验验证方法有效性。

第四章，基于分析规划与查询增强的政务数据分析方法。围绕政务场景中的结构化分析问题，提出 AP-Schema 分析规划模式、查询增强的任务分解机制、分析算子编排与标准化结果组织方法，并通过多维实验验证其性能与规划质量。

第五章，政务智能问数系统设计与实现。在前两章方法基础上，设计并实现一个政务智能问数系统，介绍系统总体架构、应用层与智能服务层实现、系统数据层存储以及系统功能展示与效果。

第六章，结论与展望。总结全文研究工作与主要创新点，分析现有工作的不足，并对后续研究方向进行展望。

1.5 本章小结

本章围绕数字政府建设和政务数据资源利用的现实需求，阐明了本文开展政务智能问数研究的背景、目标与意义；在系统梳理 Text-to-SQL、自动数据分析以

及政务数据管理与应用平台相关研究进展的基础上，归纳出领域知识显式增强不足、分析规划与查询协同不足、系统化落地能力不足三个关键问题，并说明了开展本研究既具有现实必要性，也具备明确技术可行性；进而明确了本文围绕政务数据查询生成方法、政务数据分析方法和智能问数系统实现展开研究的总体思路，并说明了全文的章节安排，为后续章节展开奠定基础。

第 2 章 相关理论与技术

本章对与本文研究相关的理论基础和关键技术进行综述，重点讨论大语言模型与工具增强、可靠查询生成、数据分析规划与结果生成，以及系统编排与服务协同等内容。相关研究表明，面向政务问数与数据分析的智能系统已不再是单一文本生成问题，而是由语义理解、结构化生成、外部工具执行、流程组织和结果表达共同构成的复合技术链^[11,15]。基于这一认识，本章按照“模型基础 - 查询技术 - 分析技术 - 系统协同”的思路展开，旨在为全文研究提供必要的知识背景和方法参照。

2.1 大语言模型与工具增强基础

大语言模型（Large Language Model, LLM）是在大规模语料上进行预训练，并通过指令对齐获得任务遵循能力的语言模型^[11]。在面向数据查询、统计分析和编排的应用中，大语言模型的价值并不只体现在通用文本生成能力上，更体现在统一语义建模、少样本任务适配、结构化推理以及与外部工具协同等方面。这些能力共同奠定了复杂智能系统的模型基础^[15,52]。

2.1.1 Transformer 与指令对齐

Transformer 以自注意力机制为核心，通过并行建模序列中不同位置之间的依赖关系，使模型能够在统一表示空间内同时处理词语语义、上下文关系和结构约束^[53]。这类架构具有较强的长距离依赖建模能力，因此更适合承载自然语言理解、结构化生成和多步骤推理等任务。

从技术演进看，GPT 类解码器模型^[8,28,54-55]强化了自回归生成能力，BERT 类模型^[56]强化了双向语义表示能力，T5^[57]则提供了统一的文本到文本建模范式。朱炫鹏等人^[52]指出，当前大语言模型的发展一方面沿着模型能力增强持续推进，另一方面也在通过推理效率优化、架构改进和工程化手段提升实际可用性。对于自然语言到 SQL、自动化分析和多步骤任务执行而言，解码器式或统一生成式模型通常更具现实适用性，因为其输出目标往往天然表现为 SQL 语句、分析计划、代码片段或结构化结果。

仅有预训练还不足以支撑复杂应用。指令微调（Instruction Tuning）通过构造“指令 - 输入 - 输出”样本，使模型学会遵循任务边界、输出格式和领域约束^[58-59]；进一步的对齐训练，如基于人类反馈的强化学习^[60]，则使模型输出更符合安全性、

可用性和稳定性要求。对于需要兼顾表达规范、统计口径和执行可靠性的应用场景而言，这种“预训练 + 任务对齐”的技术路线尤为重要^[15]。

2.1.2 上下文学习、链式推理与结构化输出

上下文学习（In-Context Learning, ICL）使模型能够在不更新参数的情况下，仅通过提示中的任务说明、数据库模式信息和少量示例完成新任务^[28,61]。这使模型能够在不同数据库、不同任务模板和不同分析需求之间快速迁移，而不必为每一种场景重新训练专用模型。在复杂数据应用中，模式描述、历史样例和输出格式约束通常都会作为上下文的一部分被显式组织进提示中，从而提升模型对当前任务的适配性。

链式推理（Chain-of-Thought, CoT）进一步提升了复杂任务中的中间步骤显式化能力^[62-63]。当用户需求涉及同比、占比、排名、条件筛选和多阶段聚合等隐含逻辑时，模型若直接输出最终 SQL 或最终结论，容易在中间语义转换中出现遗漏和幻觉。通过显式展开推理步骤，模型可以先识别指标、维度和约束，再逐步构造查询或分析计划，从而提升复杂任务的稳定性。自一致性^[64]和思维树^[65]等方法进一步说明，多路径推理与结果比较能够有效缓解单路径生成的不稳定问题。

结构化输出则把模型能力从“自由文本生成”进一步推进到“受约束结果生成”。在数据系统中，输出对象通常不是普通自然语言段落，而是 SQL 语句、JSON 计划、代码调用参数或固定槽位结果。因此，结构化输出并不是简单的后处理步骤，而是大模型推理过程的一部分。只有当模型能够在提示约束下生成字段完整、格式稳定、语义清晰的中间结果时，后续执行、校验和编排才具备可靠基础^[66]。

2.1.3 工具调用与代码执行

大语言模型擅长语义理解与生成，但在精确计算、数据库访问、代码执行和外部状态感知方面存在明显局限^[67]。因此，当前实用系统普遍采用“模型负责推理，工具负责执行”的增强范式。Toolformer^[68]、Gorilla^[69]等研究表明，模型能够学习何时调用外部工具以及如何构造调用参数；ReAct^[70]进一步把推理、行动和观察组织成闭环，使模型能够根据执行结果持续修正自身决策。

这一范式对于数据类任务尤为关键。在查询生成场景中，SQL 需要交由数据库执行并根据报错信息或执行结果进行修正；在数据分析场景中，模型生成的计划往往需要依赖代码执行环境、统计函数库和可视化组件完成落地；在系统实现层面，模型又需要嵌入由状态对象、服务节点和消息通道组成的执行流程之中。因此，工具调用不是简单的附加能力，而是把大语言模型从文本生成器转化为任务

执行中枢的重要桥梁。

总体来看, Transformer 架构、指令对齐、上下文学习、链式推理和工具增强共同构成了大语言模型在复杂数据任务中的基础能力体系。这些研究为后续的查询生成、分析规划和系统化实现提供了统一的模型视角。

2.2 面向可靠查询生成的关键技术

Text-to-SQL 旨在把用户自然语言问题转换为可在关系数据库上执行的 SQL 语句^[12,71]。若仅从任务定义看,它似乎只是“文本到代码”的转换问题;但在实际应用中,真正的难点在于自然语言、业务语义和物理数据库结构之间往往并不存在一一对应关系。因此,可靠查询生成不仅要求模型“生成语句”,更要求系统具备识别业务术语、引入口径知识、组织样例上下文、借助执行反馈修复错误并从多候选中选择最优结果的能力^[20]。

2.2.1 任务定义与核心挑战

Text-to-SQL 的基本输入是自然语言问题 Q 与目标数据库模式 S , 输出是一条语义等价、语法正确且可执行的 SQL 语句 y ^[12]。在传统公开基准中,研究重点主要集中于问题与 Schema 之间的语义对齐、复杂 SQL 结构生成以及跨库泛化能力。随着大语言模型的引入,自然语言查询数据库技术逐渐从单纯的语句翻译扩展为“检索增强、结构约束、候选选择和执行验证”相结合的整体方案^[20]。

在垂直领域场景中,这一任务通常面临三类典型挑战。第一,业务术语与物理字段之间可能存在一对多、多对一或缩写映射关系,导致模型即使理解了问题含义,也未必能准确定位字段。第二,诸如同比增长率、预算执行率、结构占比等关键指标往往并非原始字段,而是依赖隐含计算公式和统计口径,若缺乏显式知识支撑,模型容易生成语法正确但业务错误的 SQL。第三,真实业务需求兼具高频固定模式与低频复杂长尾结构,单一路径生成往往难以同时兼顾效率与准确率。沈宇等人^[16]在交通系统智能问数研究中也表明,动态 Schema 对齐、领域知识注入和提示工程对于垂直领域 NL2SQL 落地具有显著作用。

已有研究从不同角度回应这些问题。Seq2SQL^[22]、SyntaxSQLNet^[23]开启了端到端神经生成路径,RAT-SQL^[24]、BRIDGE^[25]、PICARD^[26]和RESDSQL^[27]则分别从关系建模、内容锚定、语法约束和 Schema 筛选等方面提升了查询生成可靠性。在大模型阶段,DAIL-SQL^[29]、DIN-SQL^[30]、CHASE-SQL^[31]、XiYan-SQL^[32]与OpenSearch-SQL^[33]说明,提示组织、样例检索、多路径生成与候选判别已经成为提升性能的重要手段。

2.2.2 Schema/值检索与领域知识增强

在可靠查询生成链路中，模式链接（Schema Linking）承担着“把自然语言中的实体、指标和条件映射到数据库结构”的基础作用。RAT-SQL^[24]通过关系感知编码显式建模问题 Token 与 Schema 元素之间的关系，BRIDGE^[25]利用数据库内容进行语义锚定，RESDSQL^[27]则通过排序与筛选把庞大 Schema 压缩为更适合生成的候选子模式。这些工作共同揭示了一个事实：高质量 SQL 生成的前提不是“让模型直接猜”，而是先把与当前问题最相关的结构信息准确组织出来。

对于垂直领域系统，仅依赖原始表名、列名和注释通常仍然不够。数据库中常见的字段缩写、别名表达、口径术语和隐含逻辑，往往无法被数据库模式显式刻画。因此，结构化领域知识增强成为连接业务语言与物理数据库的必要桥梁。一类方法通过补充别名、样例值、字段说明等语义提示提升模式可读性；另一类方法则进一步把业务术语映射、逻辑公式和值域约束组织为可检索知识单元，并在在线推理时注入问题相关片段^[16,20]。这类思想本质上都是通过显式知识组织降低模型在字段绑定和业务理解上的歧义。

值检索与动态样例也是这一链路的重要组成部分。对包含行政区划、项目名称、机构名称等实体的问题而言，仅靠模型记忆很难稳定命中正确取值，向量检索和近邻召回可以作为值匹配与样例选择的关键外部支撑。在大模型 Text-to-SQL 中，DAIL-SQL^[29]与OpenSearch-SQL^[33]均证明了高相关动态样例对生成质量的重要影响。这说明可靠查询生成并不是单轮提示行为，而是“检索 - 组织 - 生成”的联合过程。

2.2.3 候选生成、执行反馈与结果选择

大模型时代的 Text-to-SQL 系统逐渐从“单答案生成”转向“多候选生成 + 执行反馈 + 最优选择”。其根本原因在于复杂 SQL 问题往往存在较高的推理不确定性：单次生成容易受到提示表述、随机采样和局部推理路径的影响，从而遗漏某个条件、错误绑定某个字段或采用错误聚合方式。因此，多路径候选生成不再只是简单的重复采样，而是通过不同提示范式、不同分解路径和不同温度设置主动扩大候选空间。

CHASE-SQL^[31]和XiYan-SQL^[32]表明，多生成器和多推理路径能够显著提升复杂问题覆盖度；Alpha-SQL^[34]则进一步将 SQL 生成建模为搜索过程，说明复杂查询更适合采用“生成与评估交替”的策略。另一方面，PICARD^[26]等工作说明，语法约束只能保证“写得像 SQL”，却不能保证“问得对业务”，因此执行反馈成为进一步验证候选质量的重要机制。当 SQL 真实执行后，系统可以根据报错信息、

空结果、字段不匹配等反馈开展修复，从而把数据库引擎转化为事实校验器。

候选选择是保证最终输出质量的最后一道关口。一致性投票适合处理低复杂度任务，但在存在业务逻辑冲突或执行表现差异时，仍需要更细粒度的判别机制。近年来的偏好优化和候选判别方法表明，结合执行结果、语义一致性和任务约束进行成对比较，通常比简单投票更可靠^[31-32]。总体来看，可靠查询生成正在从“单模型直接生成”转向“检索增强、知识注入、候选比较和执行验证”协同作用的综合范式^[20]。

2.3 面向数据分析的规划与结果生成技术

如果说 Text-to-SQL 解决的是“把数据取对”，那么面向数据分析的智能技术关注的则是“如何围绕已获取数据开展合适的分析并形成可理解的结果”。与查询任务相比，数据分析任务具有更强的开放性：用户通常不会直接给出完整的分析步骤，而是以自然语言提出一个分析目标，例如“分析近两年各区财政收入变化并说明波动原因”。系统因此需要先把需求转化为可执行规划，再调用查询、计算与可视化工具，最终输出图表、表格和文字洞察^[13-14]。随着大语言模型在政务与行业场景中的应用深化，数据分析与决策支持也逐渐成为重要落地方向^[15,50]。

2.3.1 分析任务链条与中间规划

已有研究普遍将自动数据分析过程拆分为需求理解、分析规划、工具执行和结果生成等阶段^[13,21]。其中，分析规划处于承上启下的位置：它既要把自然语言中的分析对象、指标、维度、时间范围和展示要求显式化，又要决定哪些步骤应由查询模块完成，哪些步骤保留到分析层处理。若缺乏这一中间层，系统就容易在复杂需求下出现“先取什么数据并不清楚”“展示和计算混在一起”“结果虽能生成但难以验证”等问题。

InsightPilot^[21]将数据探索拆解为一系列分析操作，说明分析任务本质上并非单步问答，而是带有过程结构的决策链。Analysts^[14]则从更广泛视角评估了大语言模型作为数据分析者的可行性，指出模型在分析规划、统计执行和结果解释上的能力并不均衡，尤其需要外部约束来提高规划与输出质量。在政务和行业场景中，这种约束更加重要，因为分析任务通常要遵循固定口径、固定展示习惯和更强的可复核要求^[15,50]。

基于此，结构化中间表示成为提高可控性的常见路径。它的核心思想不是让模型一步产出最终结论，而是要求模型先输出一个受约束的分析计划，用以描述分析类型、关注指标、分析维度、筛选条件、计算方式以及展示规格。常见的中间

表示包括计划槽位、任务图、结构化脚本和可解析 JSON 对象等。这类方式有助于把开放式需求转化为可校验、可复用、可执行的分析对象，从而提升系统整体稳定性。

2.3.2 代码生成、分析算子与可视化组织

在分析规划确定之后，系统还需要完成计算和表达两个层面的执行。代码生成模型如 Codex^[38]、Code Llama^[39]、StarCoder^[40]和 WizardCoder^[41]证明了大模型可以根据自然语言描述生成较高质量程序代码，这为自动统计分析、数据变换和图表绘制提供了技术前提。但在实际系统中，直接让模型自由生成整段分析代码，往往会带来鲁棒性不足、重复逻辑过多和结果难以复核等问题。

因此，越来越多的系统开始采用“规划+算子+工具”的组织方式。Data Interpreter^[13]通过代码执行环境完成端到端分析，TaskWeaver^[44]强调代码优先与任务分工，LIDA^[42]和Chat2VIS^[43]则从可视化生成角度展示了模型如何驱动图表代码与视觉表达。ChartGPT^[47]进一步说明，自然语言到图表之间并非简单模板映射，而是涉及图表类型选择、坐标映射和表达目标对齐。与此同时，结构化输出评测研究表明，若缺少明确槽位和格式约束，模型在表格与结构数据生成上仍容易出现字段遗漏和格式漂移^[66]。

这说明，数据分析结果生成不宜完全依赖自由代码生成，而更适合在分析算子和可视化规则层面引入明确边界。在这种思路下，模型负责生成分析计划和调用意图，系统则依据预定义的轻量算子库完成排序、占比、透视、标注和图表组织等稳定操作。这样既保留了大模型的灵活性，又提高了统计过程和展示结果的一致性。

2.3.3 查询与分析分层协同

分析系统中一个常见设计误区，是让分析模块重新承担数据库理解与 SQL 生成职责。这样虽然看似减少了模块数量，但实际上会造成查询逻辑与分析逻辑混杂，导致一旦上游取数有误，后续图表和洞察都会建立在错误事实之上。因此，越来越多的研究强调把“数据获取”和“数据分析”视作两个职责清晰但密切协同的阶段^[13-14]。

分层协同的基本原则是：凡涉及数据库模式理解、复杂字段绑定、跨表关联和统计口径计算的操作，应尽量下沉到查询层完成；凡只依赖已获取结果的重组、排序、对比、占比和注释等操作，则由分析层负责。这种划分的直接好处有三点。第一，它复用了可靠查询模块在模式链接、逻辑增强和执行修复方面的已有能力，

避免分析阶段重复犯错。第二，它使分析规划能够围绕统一的中间表示展开，便于对查询约束和分析约束分别建模。第三，它提升了系统整体可解释性，因为每一步究竟是“为了取数”还是“为了分析”都能够被明确追踪。

总体来看，面向数据分析的智能技术正逐步从“直接生成结论”转向“结构化规划、工具执行和结果组织”相结合的实现路径。这种分层化、可执行、可复核的分析范式，已经成为复杂数据应用的重要发展方向^[15,50]。

2.4 面向系统实现的工作流编排与服务协同

当查询与分析能力从单点方法发展为可交互系统后，研究关注点便进一步延伸到工程实现层面。一个实用系统不仅要给出结果，还需要组织任务流程、维护状态、回传异常并沉淀中间产物，以支持复核、追问和问题定位。这使得工作流编排、状态管理、服务协同和角色分工成为大语言模型应用落地时不可回避的关键技术^[4-5,50]。

2.4.1 工作流图编排、状态管理与异常回传

大语言模型应用逐步走向复杂系统后，单轮提示已经难以承载完整业务流程。一个典型任务往往需要经历需求解析、知识检索、SQL 生成、执行验证、结果封装和前端回传等多个阶段。因此，工作流图编排成为组织模型能力与系统组件的重要方式。从原理上看，工作流图把任务拆分为若干节点，每个节点负责相对单一的职责，节点之间通过显式状态对象和条件边连接，从而形成可追踪、可恢复的执行路径。

ReAct^[70]提供了“推理 - 行动 - 观察”的通用闭环思想，表明模型驱动任务执行更适合放入可循环、可反馈的流程而非一次性输出。对系统实现而言，这一思想需要进一步工程化：系统要把模型调用、数据库执行、文件生成和消息回传等步骤纳入统一状态机中，并对成功、失败、重试和终止等状态进行管理。周祥生等人^[72]关于大模型推理任务调度的研究也说明，随着模型能力嵌入真实业务链路，任务优先级、资源分配和状态调度会直接影响系统稳定性与用户体验。同时，政务垂类大模型的应用实践表明，只有把模型能力放入可管理、可审计的服务流程中，才能兼顾灵活性与可控性^[17,51]。

2.4.2 轻量级 Agent 协同与角色分工

在复杂任务中，不同节点往往承担不同角色：有的负责路由请求，有的负责生成查询，有的负责组织分析，有的负责汇总结果。这类“角色分工 + 消息协同”的设计

与近年来的 Agent 研究存在天然联系。AutoGen^[73]强调通过多角色对话组织工具调用与任务分工, MetaGPT^[74]强调基于标准操作流程的结构化协同, CAMEL^[75]则展示了角色扮演框架下的任务协商能力。郭先会等人^[76]从中文综述角度指出, 大语言模型智能体通常围绕任务规划、工具执行、记忆组织和评测机制展开, 其工程价值很大程度上取决于角色职责是否清晰、工具接口是否稳定。

不过, 在真实业务场景中, 更具可操作性的往往不是“重型多智能体社会模拟”, 而是轻量级服务协同。也就是说, 系统不必追求大量 Agent 之间的开放式对话, 而是更强调把查询、分析、调度和结果组织等职责稳定封装为可复用服务角色。李轶夫^[77]指出, 生成式大模型智能体真正形成工程价值的前提, 是把角色能力、工具接口和业务场景有机结合, 而不是停留在概念展示层面。相关政务实践也说明, 分层设计、模块化集成和模型服务化部署, 是保障系统稳定落地的重要途径^[17,50-51]。

综合来看, workflow编排负责组织任务过程, 状态管理负责约束执行边界, 轻量级 Agent 协同则有助于明确角色职责并降低上下文混杂。这些研究共同构成了大语言模型系统从“能回答”走向“能稳定运行”的工程技术基础。

2.5 本章小结

本章围绕与本文研究相关的理论与技术, 对大语言模型基础、可靠查询生成、数据分析规划与结果生成, 以及系统编排与服务协同等内容进行了综述。

在模型基础方面, Transformer 架构、指令对齐、上下文学习、链式推理和工具增强共同塑造了大语言模型处理复杂数据任务的核心能力。在查询生成方面, Schema 链接、领域知识增强、值检索、动态样例、多候选生成和执行反馈构成了提高 NL2SQL 可靠性的关键技术链。在数据分析方面, 结构化规划、代码执行、分析算子和查询分析分层协同体现了从开放式需求到规范化分析结果的主流实现思路。在系统实现方面, workflow编排、状态管理与轻量级 Agent 协同则为复杂智能系统的稳定运行、可追溯性和工程落地提供了重要支撑。

总体而言, 上述研究共同描绘了面向复杂数据应用的技术演进方向, 即从单一模型生成逐步走向“知识增强、工具执行、流程组织和结果验证”协同作用的综合范式。

第3章 基于逻辑增强与异构协同的政务数据查询生成方法

3.1 引言

文本到 SQL 生成 (Text-to-SQL) 是将自然语言问题自动转换为可在关系数据库上执行的结构化查询语言的语义解析任务^[12], 是实现“智能问数”和降低数据分析门槛的关键技术。在政务领域, 随着数字政府建设的深入, 海量的人口、经济、社会等异构数据急剧增长, 使得非技术背景的公务人员能够直接、高效地从数据中获取决策支持显得尤为迫切。

本章提出的 Text-to-SQL 方法, 其任务形式化定义为: 给定用户的自然语言问题 Q 、目标数据库模式 S 、领域知识库 K 以及动态样例库 F , Text-to-SQL 任务的目标是生成一条可正确执行并返回预期结果的 SQL 查询语句, 即与用户意图最大化一致:

$$y^* \equiv \arg \max_{y \in Y} P(y \mid Q, S, K, F) \quad (3-1)$$

其中 Y 为符合 SQL 语法的候选集合, θ 为模型参数。

本章的研究目标是面向政务数据查询这一具体应用场景, 以系统性解决复杂政务语义下查询生成的正确性、执行成功率与鲁棒性问题。以一个典型的政务查询为例, 当用户提出“2023 年各区县的一般公共预算收入同比增长率是多少?”而这一看似简单的问题时, 系统需要理解“一般公共预算收入”对应的物理字段、“同比增长率”隐含的跨年度计算逻辑以及“区县”维度的分组聚合方式, 才能生成正确的 SQL 查询。这一过程涉及的业务知识远超数据库模式本身所能表达的信息边界。

与通用领域的 Text-to-SQL 任务相比, 政务数据查询面临着更为突出的复杂性挑战, 主要体现在以下方面:

(1) 业务术语的语义模糊与别名多样。政府工作存在大量专业术语及其简称、别名和口语化表达。例如, “一般公共预算收入”可能被简称为“一般预算收入”或“公共预算收入”, 而数据库中的物理字段名可能为 `ybsr` 等缩写形式。这种多对一的映射关系显著增加了模式链接的难度。

(2) 指标计算逻辑的隐含性。大量政务指标并非数据库中的直接存储字段, 而需要通过特定的计算公式推导得出。例如, “同比增长率”需要通过当期值与上期值的差值除以上期值来计算, “预算执行率”需要执行数除以预算数。这些隐含的

计算逻辑未显式存在于数据库模式中，导致大语言模型在面对此类查询时极易产生“逻辑幻觉”——即生成语法正确但业务逻辑错误的 SQL 语句。

(3) 查询结构的复杂性与多样性。SQL 查询的复杂度分布呈现明显的长尾特征：高频需求多为结构相对固定的简单查询，而低频需求则可能涉及多层嵌套子查询、跨表关联、条件聚合等复杂 SQL 结构。单一的生成范式难以同时兼顾这两类需求，对简单查询可能引入不必要的推理冗余，对复杂查询则可能因推理深度不足而导致准确率骤降。

上述问题分别对 Text-to-SQL 流程中的模式链接、候选生成和结果判别三个核心环节产生影响。基于此，本章的方法设计围绕以下三个目标展开：第一，通过构建领域知识库并将其显式注入数据库模式，同时设计一个应用于快速理解政务领域的数据库模式，以提升模式链接环节对政务语义的理解准确性；第二，通过设计异构协同的双路生成机制，平衡高频标准需求与低频复杂长尾需求的生成效率与质量；第三，通过引入执行反馈修复机制与基于微调的候选判别模型，提升最终查询结果的稳定性与鲁棒性。

3.2 总体框架设计

如图3-1所示，本章提出的基于逻辑增强与异构协同的 Text-to-SQL 方法包含离线知识准备和在线推理生成两条链路，由四个核心模块组成：离线数据预处理模块、模式链接模块、候选生成模块和候选判别模块。

离线阶段负责为在线推理提供高可用的辅助数据支撑。具体而言，该阶段从业务数据库中提取字符型列及其取值构建向量索引数据库 (*VecDB*)，为后续的值检索提供基础；通过人工梳理与结构化组织，构建包含业务术语映射、逻辑计算公式和值域约束的政务领域知识库 K ；同时，利用大语言模型对已有的“问题-SQL”对进行知识解构，生成包含中间推理链的动态样例库 F 。

在线阶段以用户的自然语言查询为输入，依次经过以下处理流程。首先，模式链接模块从原始数据库模式中检索与问题相关的表、列和值信息，并注入领域知识库中的业务术语、计算公式和值域约束，将原始数据库模式 S 转化为面向当前问题的逻辑增强模式 (LA-Schema) S^* 。随后，候选生成模块采用异构协同策略，通过逻辑映射生成器和渐进分治生成器两条并行推理路径，分别从领域逻辑映射和渐进式分解推理的角度生成多样化的 SQL 候选集。每个生成器基于大模型较高温度设置下并行采样生成候选 SQL 查询。对于生成过程中出现的语法错误或执行异常，查询修复器利用执行反馈信息引导大语言模型进行自反思修复。最终，候选判别模块通过微调的二分类选择模型对候选集进行配对比较与得分聚合，选出

最优的 SQL 查询语句作为最终输出。

各模块之间的数据流转关系形成了“知识准备—模式增强—候选生成—修复优化—判别选择”的完整闭环，其中离线知识准备为在线推理持续提供领域先验支撑，在线推理的执行结果又可反馈用于丰富样例库，实现系统能力的渐进增强。




图 3-1 逻辑增强与异构协同的 Text-to-SQL 框架图

3.3 离线知识准备

离线数据预处理模块的目标是为后续在线推理生成提供低冗余、高可用的辅助数据。本模块通过构建多维度的数据知识支撑体系，为后续模式链接和候选生成过程提供精确的语义和逻辑基础。该支撑体系包含向量索引数据库、政务领域知识库以及动态样例库三个核心组件。

3.3.1 向量库构建

为保障大语言模型生成的 SQL 语句与底层数据库实际状态的一致性，本模块构建了高质量的向量索引数据库 *VecDB*，用于模式链接过程中的值检索。

具体构建流程如下。首先，从数据库中提取所有字符型列 C 及其对应的取值 v ，构造联合文本序列 $s = [C : v]$ 。通过将值的向量表示携带其所属列的上下文信

息，以帮助在检索时区分不同列下的同名值。

然后，利用预训练编码模型 BGE-m3^[78]将上述文本序列映射为高维语义向量 $\mathbf{h}$ 。此外考虑到政务数据库的规模庞大，为优化存储开销并提升检索效率，仅对字符串类型数据进行向量化。所有向量存入基于分层可导航小世界图（Hierarchical Navigable Small World, HNSW）^[79]的索引结构中。HNSW 通过构建多层跳跃链接的近邻图结构，在高维空间中实现对数级别的近似最近邻检索，相较于暴力搜索在大规模向量库上具有显著的效率优势，同时保持较高的召回率。最终向量库构建过程可表述为：

$$\begin{cases} \mathbf{h} = \text{BGEEncode}([C : v]) \\ \text{VecDB} = \{(\text{HNSW}(\mathbf{h}), C, v) \mid \forall C, v\} \end{cases} \quad (3-2)$$

向量数据库在在线阶段承担两方面的核心作用：一是通过语义相似度检索实现对用户问题中关键实体的精准召回，即使存在拼写差异或表述变化也能准确定位对应的数据库值；其次是为动态样例检索提供嵌入向量基础，使系统能够根据当前问题的语义特征检索最相关的历史样例。

3.3.2 政务领域知识库构建

针对政务数据查询中业务逻辑复杂且语义模糊的问题，本文构建了结构化的政务领域知识库 $K = \{B, L, V\}$ 。不同于传统的非结构化文本注释方式，该知识库采用结构化三元组形式存储先验业务知识，旨在为后续的模式链接和候选生成过程提供确切的逻辑增强。

知识库由以下三个组件构成：

(1) 业务术语映射 B ：记录政务领域中复杂业务指标与物理数据库字段之间的对应关系。例如，三元组（“一般公共预算收入”, $ybsr$, “一般公共预算收入金额字段”）将业务术语映射到具体的数据库字段。

$$B = \{(t_i, c_i, d_i)\}_{i=1}^{|B|} \quad (3-3)$$

其中 t_i 为业务术语， c_i 为对应的物理字段或字段组合， d_i 为转换说明。

(2) 逻辑计算器 L ：存储复杂的计算公式及聚合逻辑，将其表示为 SQL 代数表达式。例如，对于“同比增长率”这一指标，其 SQL 表达式为（当期值 - 上期值）/ 上期值 * 100。通过将复杂的业务计算逻辑预先编码为 SQL 代数表达式并以虚拟列的形式注入数据库模式 Schema，模型在生成 SQL 时可以直接调用这些预定义的逻辑块，从而规避了模型在处理大规模复杂计算公式时的推理冗余和盲

目判断。

$$L = \{(m_j, f_j, e_j)\}_{j=1}^{|L|} \quad (3-4)$$

其中 m_j 为指标名称, f_j 为计算公式的 SQL 表达式, e_j 为计算说明。

(3) 值域约束器 V : 记录特殊业务字段的取值范围或枚举值。例如, ($xzqh, \{$ “荣华街道”, “博兴街道”, “经济开发区”, ... $\}$) 记录行政区划名称字段的合法取值。值域约束的引入能够帮助模型生成包含正确 WHERE 条件的 SQL 语句, 避免因值不匹配导致的查询结果为空。

$$V = \{(c_k, R_k)\}_{k=1}^{|V|} \quad (3-5)$$

其中 c_k 为字段名, R_k 为该字段的合法取值范围或枚举值集合。

知识库的来源包括政务业务术语表、字段文档、业务统计口径规则以及领域专家整理的历史问答知识。其标注过程以人机协同方式, 人工标注为主, 辅助以大语言模型辅助标注。知识的归一化组织遵循“术语—标准表达—对应字段/取值—业务说明”的统一结构, 便于在模式链接阶段进行高效检索与注入。

3.3.3 动态样例库构建

少样本 (Few-shot) 学习是辅助大语言模型进行 SQL 生成的一种重要方法。研究表明, 示例问题的质量和与当前问题的相关性对 Text-to-SQL 任务的生成效果具有关键影响^[29,33]。基于此, 本模块采用动态少样本学习策略, 而非固定的少样本集合, 以提高大语言模型在不同查询场景下的适应性和生成质量。

动态样例库的构建流程如图3-2所示。首先, 利用大语言模型对原始的“问题-SQL”对进行知识解构, 生成中间层的思维链 (Chain-of-Thought, CoT) 信息。该过程将每个样例从 $\langle \text{Query}, \text{SQL} \rangle$ 二元组扩展为包含完整推理逻辑的 $\langle \text{Query}, \text{CoT}, \text{SQL} \rangle$ 三元组。以此构建一个逻辑表达能力更强的样例库。CoT 信息的具体组成如表3-1所示。这种结构化的推理链不仅为后续生成器提供了更丰富的推理线索, 也使得模型能够通过模仿样例中的推理过程来提升自身的逻辑表达能力。

表 3-1 思维链 (CoT) 信息的组成要素

要素	标识	说明
查询意图分析	reason	对用户问题的语义理解与意图解读
关键列	columns	查询涉及的数据库列
筛选值	values	WHERE 等筛选条件中使用的具体值
SELECT 内容	SELECT	SELECT 子句应返回的字段与表达式
类 SQL 语句	SQL-like	忽略连接条件的简化 SQL 骨架

而在在线推理阶段，当接收到用户查询 Q 时，系统启动端到端的动态样例检索流程，即从样例库 F 中选取与当前问题最相关的 k 个样例，以构建高质量的少样本提示。该流程融合了掩码问题相似性（Masked Question Similarity, MQS）^[29] 与查询结构相似性的双重度量，从问法相似和 SQL 相似两个维度综合筛选样例。

具体而言，检索过程包含以下步骤。首先，对用户查询 Q 执行掩码操作，将其中的领域特定实体（如表名、列名、具体值）替换为统一占位符，得到掩码后的查询 Q' ：

$$Q' = \text{Mask}(Q) \quad (3-6)$$

随后，同样利用预训练编码模型 BGE-m3 将 Q' 映射为稠密向量表示 $v_{Q'} = \text{Enc}(Q')$ ，并在同样经过掩码处理的样例问题向量库中，使用基于 HNSW 的近似 k 近邻检索（Approximate Nearest Neighbor, ANN）算法召回一批候选样例集合 F_{cand} 。掩码操作使得相似度计算更关注问题的结构与语义特征，而非表面的实体匹配，从而有效提升跨数据库场景下的样例检索质量。




图 3-2 动态样例库构建流程图

其次在候选样例召回的基础上，系统进一步引入查询结构相似度对候选样例进行精排。具体地，先利用一个初步预测模型为 Q 生成近似 SQL 查询 $\hat{s}_Q$ 作为目标 SQL 的估计，然后将 $\hat{s}_Q$ 与每个候选样例的 SQL 查询 s_i 根据 SQL 关键词编码为二元离散语法向量，计算结构相似度 $\text{Sim}_{\text{sql}}(\hat{s}_Q, s_i)$ 。最终的样例排序综合考虑问题相似度与查询相似度，并通过预定义阈值 τ 过滤查询相似度不足的样例：

$$F_k = \text{Top-}k \left\{ \text{Sim}_{\text{ques}}(v_{Q'}, v_{Q'_i}) \mid \text{Sim}_{\text{sql}}(\hat{s}_Q, s_i) > \tau \right\}_{f_i \in F_{\text{cand}}} \quad (3-7)$$

其中 Sim_{ques} 为掩码问题向量间的相似度, F_k 即为最终选取的 k 个动态样例。选定的样例以 $\langle \text{Query}, \text{CoT}, \text{SQL} \rangle$ 三元组的形式拼接至提示模板中, 与数据库模式、检索到的相似值及领域规则共同构成完整的少样本提示, 以引导大语言模型生成目标 SQL。

最终的动态样例库具备渐进更新的能力。当渐进分治生成器产生的候选 SQL 被判别模型确认为最优答案后, 该查询及其对应的推理过程可作为新的样例加入样例库 (可控制是否开启), 实现样例库的持续丰富与质量提升。

3.4 基于逻辑增强的模式链接

模式链接是 Text-to-SQL 任务中的关键环节, 其目标是将用户的自然语言查询与数据库模式中的元素 (包括表、列和值) 相关联, 从庞大的数据库模式中筛选出最小必要且包含丰富语义信息的数据库子模式^[31]。本节提出一种基于逻辑增强的模式链接方法, 通过动态检索元素信息、选取关键模式片段并注入领域逻辑信息, 将原始数据库模式 S 转化为面向特定问题 Q 的最小增强模式 S^* 。

该方法的处理流程包含检索、筛选和增强三个阶段, 其完整算法描述如算法3.1所示。

检索阶段旨在从数据库中搜索与查询潜在关联的值和列。该阶段首先以用户查询 Q 、动态样例 F_u 及领域知识库 K 为输入, 利用大语言模型识别用户问题中的关键词与实体, 获取实体集合 W_{entity} 。随后, 对 W_{entity} 中的每个实体 w 分别执行列检索与值检索。列检索基于实体 w 与列描述之间的语义相似度, 筛选每个实体对应的 Top- k 候选列。值检索基于 HNSW 索引从向量数据库中快速召回语义最近邻候选集 V_{cand} , 并利用嵌入向量的余弦相似度进行精排, 以实现目标值及其所属列的精准定位。检索到的候选列、匹配值及其所属表共同构成候选模式片段集合 S_{cand} 。

筛选阶段旨在将检索得到的表、列、值集合缩减为生成 SQL 所需的最小数据库模式。此过程根据检索得到的候选列元素集合, 让大语言模型评估每个列与用户查询的相关性, 过滤无关列, 最终得到最小数据库模式 S_{filter} 。该筛选步骤能够有效降低后续生成阶段的输入规模, 减少因冗余信息导致的模型注意力分散和幻觉问题。

增强阶段是本方法的核心创新所在。在获得最小数据库模式后, 系统从领域知识库 K 中提取与当前查询相关的业务知识, 并将其显式注入模式表示中, 形成逻辑增强模式 LA-Schema。LA-Schema 的组织方式参照 M-Schema^[32]的半结构化格式, 以层次化的方式展示数据库、表和列之间的结构关系, 并在此基础上添加政

算法 3.1: 基于逻辑增强的模式链接算法

Input: 用户查询 Q , 原始数据库模式 S , 列检索召回数 k , 动态样例 $F_u = \{f_1, f_2, \dots, f_k\}$, 领域知识库 $K = \{B, L, V\}$, 向量数据库 VecDB, 大语言模型 LLM

Output: 最小增强模式 S^*

```

1 初始化: 候选模式片段集合  $S_{\text{cand}} \leftarrow \emptyset$ ;
   // 阶段一: 检索
2   $W_{\text{entity}} \leftarrow \text{LLM}(Q, F_u, K)$ ; // 实体提取
3  foreach  $w \in W_{\text{entity}}$  do
4       $C_{\text{topk}} \leftarrow \text{SemanticSearch}(w, C, k)$ ; // 列检索
5       $V_{\text{cand}} \leftarrow \text{HNSW}(w, \text{VecDB})$ ; // 值近邻召回
6       $\text{val} \leftarrow \arg \max_{v \in V_{\text{cand}}} \text{Sim}(\text{Enc}(w), \text{Enc}(v))$ ; // 语义精排
7       $S_{\text{cand}} \leftarrow S_{\text{cand}} \cup \{C_{\text{topk}}, \text{val}, \text{Table}(\text{val})\}$ ;
8  end
   // 阶段二: 筛选
9   $S_{\text{filter}} \leftarrow \text{LLM}(Q, S_{\text{cand}})$ ; // 列相关性评估与筛选
   // 阶段三: 增强
10  $C_{\text{alias}}, C_{\text{virtual}}, D_{\text{prompt}} \leftarrow \text{GetKnowledge}(W_{\text{entity}}, B, L, V)$ ;
11  $S^* \leftarrow \text{TransLASchema}(S_{\text{filter}}, C_{\text{alias}}, C_{\text{virtual}}, D_{\text{prompt}})$ ; // 注入知识并转换为
   LA-Schema
12 return  $S^*$ 

```

务领域业务知识的显式表达。具体的增强内容包括三个层面:

(1) **术语归一与别名扩展:** 对于知识库 B 中与当前查询匹配的业务术语映射, 在对应字段上添加 **Business Term** 标记, 标注该字段在业务语义上的对应关系。例如, 当字段 `ybsr` 被识别为“一般公共预算收入”的物理存储字段时, LA-Schema 中会以 `[Business Term: 一般公共预算收入  $\rightarrow$  ybsr]` 的形式进行标注。

(2) **虚拟逻辑列注入:** 对于知识库 L 中匹配的计算指标, 在 LA-Schema 中创建虚拟列 (Virtual columns), 并附带预定义的 SQL 计算公式。例如, 对于“同比增长率”指标, 系统会注入一个标记为 `[Logical Term: 同比增长率, Formula: (当期值 - 上期值) / 上期值 * 100]` 的虚拟字段。这样, 大语言模型在生成 SQL 时可以直接引用预定义的计算逻辑, 而无需从零开始推理复杂的业务公式。

(3) **列值提示与约束:** 对于知识库 V 中匹配的值域约束以及通过值检索获得的匹配值, 在对应列上添加 **Value Term** 标记, 提示模型在 WHERE 条件中使用正确的匹配值。

为直观说明 LA-Schema 的增强效果, 以下给出一个对比示例。对于查询“帮我找出所有状态为已完工的民生项目, 并计算它们的资金结余率。”, 原始 DDL Schema、M-Schema 与 LA-Schema 的展示结果如表3-2所示。

表 3-2 原始 DDL Schema、M-Schema 与 LA-Schema 对比示例

模式类型	表示内容
DDL Schema	<pre>CREATE TABLE t_gov_proj(p_id INTEGER PRIMARY KEY, p_name VARCHAR, amt_tot INTEGER, amt_act INTEGER, p_type TINYINT, status TINYINT, p_year INTEGER)</pre>
M-Schema	<pre>[DB_ID] gover_database [Schema] # Table: t_gov_proj [(p_id: INTEGER, Primary Key, 项目编码, Examples:[1001,1002,1003]), (p_name: VARCHAR, 项目名称, Examples:[" 经开区智慧城市规划服务项目", "T 小区安居提升工程项目", "E 社区服务中心数字化基础设置建设"]), (amt_tot: INTEGER, 总概算, Examples:[1000000,2000000,3000000]), (amt_act: INTEGER, 实际支出, Examples:[100000,200000,300000]), (p_type: TINYINT, 项目类型, Examples:[1,2,3]), (status: TINYINT, 状态, Examples:[0,1]), (p_year: INTEGER, 年份, Examples:[2023,2024,2025])]</pre>
LA-Schema	<pre>[DB_ID] gover_database [Schema] # Table: t_gov_proj [Physical Columns: (p_id: INTEGER, Primary Key, 项目编码, Examples:[1001,1002,1003]), (p_name: VARCHAR, 项目名称, Examples:[" 经开区智慧城市规划服务项目", "T 小区安居提升工程项目", "E 社区服务中心数字化基础设置建设"]), (amt_tot: INTEGER, 总概算, Examples:[1000000,2000000,3000000]), (amt_act: INTEGER, 实际支出, Examples:[100000,200000,300000]), (p_type: TINYINT, 项目类型, Examples:[1,2,3]), Business Term:{" 民生项目": " 民生工程"}, Value Term:{" 民生工程":1, " 基础设施":2, " 产业扶持":3}), (status: TINYINT, 状态, Examples:[0,1]), Value Term:{" 进行中":0, " 已完工":1}), (p_year: INTEGER, 年份, Examples:[2023,2024,2025]) Virtual Columns: (balance_rate: Logical Term, 资金结余率, Examples:[0.1,0.2,0.3], Formula:"(amt_tot-amt_act)/amt_tot")]</pre>

可以看到，原始 DDL Schema 仅提供了最基本的列名与数据类型，缺乏任何语

义信息；M-Schema 在此基础上补充了中文列描述和示例值，但仍无法表达业务术语映射、值域约束等领域知识。而 LA-Schema 通过显式注入 Business Term、Value Term 与 Virtual Columns 等增强信息，使大语言模型能够准确理解“民生项目”对应的物理字段取值、“已完工”的编码映射以及“资金结余率”的计算公式，从而显著降低模式链接阶段的错误率。

3.5 异构候选生成

在政务数据查询场景中，用户查询的复杂度分布呈现显著的长尾特征^[80]，即高频需求往往是结构相对固定的标准查询，而低频需求可能涉及多层嵌套、多表关联和复杂聚合等高难度 SQL 结构。单一的生成路径在处理这种高度异构的查询分布时存在固有局限：对于简单查询，过度复杂的推理策略会引入冗余步骤并增加出错风险；对于复杂查询，直接映射式的生成方式又难以捕获深层的逻辑关系^[31]。

为此，本文设计了一种异构协同生成框架，包含旨在捕获高频业务逻辑的逻辑映射生成器以及处理复杂推理深度的渐进分治生成器。通过并行驱动两个推理范式截然不同的生成器，构建多样化的 SQL 候选池，以提升系统对各种复杂度查询的覆盖能力。生成阶段允许大语言模型在非零温度^[81]设置下执行随机采样，每个生成器并行生成 n_c 个候选 SQL 查询，最终总计产生 $2n_c$ 个多样性的 SQL 候选集。

3.5.1 逻辑映射生成器

逻辑映射生成器深度集成了本章提出的 LA-Schema 架构，其推理机制建立在领域逻辑映射的基础之上。该生成器通过引导大语言模型对 LA-Schema 中的领域先验进行识别与调用，其包括业务术语的语义对齐、虚拟逻辑列的公式引用以及值域约束的条件匹配。以有效地将复杂的 SQL 构造过程从底层的算子推导转化为对预设逻辑块的检索与组装。其完整流程如算法3.2所示。

算法中，BuildRules() 构建的映射规则指令明确要求模型遵循以下约束：（1）优先使用 LA-Schema 中标记为 Virtual Column 的虚拟逻辑列，直接在 SQL 中调用其预定义的计算公式；（2）识别并转换 Business Term 标记的业务术语，使用映射后的物理字段替换原始表达；（3）利用 Value Term 标记的匹配列值，确保 WHERE 条件中使用与数据库一致的标准取值；（4）直接输出最终的可执行 SQL，不作过多中间解释。生成阶段在非零温度下对同一提示执行 n_c 次独立采样，以获得多样化的候选 SQL 集合 $\mathcal{C}_{lm}$ 。

该生成器的核心优势在于效率高、对常见查询模式适应性强。对于政务场景

算法 3.2: 逻辑映射生成算法

Input: 用户查询 Q , LA-Schema 增强模式 S^* , 动态样例 $F_u = \{f_1, f_2, \dots, f_k\}$, 采样数 n_c , 大语言模型 LLM

Output: 候选 SQL 集合 $\mathcal{C}_{lm}$

```

1 初始化: 候选集合  $\mathcal{C}_{lm} \leftarrow \emptyset$ , 提示  $P \leftarrow \emptyset$ ;
   // 构建提示模板
2  $P \leftarrow P \oplus \text{FormatFewShot}(F_u)$ ;           // 拼接动态少样本示例
3  $P \leftarrow P \oplus S^*$ ;                         // 拼接 LA-Schema 增强模式
4  $R \leftarrow \text{BuildRules}()$ ;                     // 构建映射规则指令
5  $P \leftarrow P \oplus R \oplus Q$ ;                   // 拼接规则指令与用户查询
   // 多次采样生成候选 SQL
6 for  $i \leftarrow 1$  to  $n_c$  do
7    $\hat{y}_i \leftarrow \text{LLM}(P, \text{temperature} > 0)$ ; // 随机采样生成 SQL
8    $\mathcal{C}_{lm} \leftarrow \mathcal{C}_{lm} \cup \{\hat{y}_i\}$ ;
9 end
10 return  $\mathcal{C}_{lm}$ 

```

中高频出现的指标查询、条件筛选和简单聚合等标准需求, 逻辑映射生成器能够充分利用 LA-Schema 中预置的领域逻辑, 快速而准确地完成 SQL 生成, 避免了不必要的推理链条展开。

3.5.2 渐进分治生成器

与逻辑映射生成器的直接映射策略不同, 渐进分治生成器采用渐进式生成与动态少样本的联合方式, 以应对知识库未覆盖的复杂需求, 如多层嵌套逻辑、多条件组合聚合以及跨表关联查询等。

渐进式生成策略本质上是一种面向 Text-to-SQL 任务定制化的思维链方法^[62], 其核心在于将复杂的 SQL 生成任务拆解为多维度、结构化的子任务序列, 引导大语言模型通过逐步推理深度理解查询逻辑。该策略借鉴了 CHASE-SQL^[31]中的分治思想和 OpenSearch-SQL^[33]中的 SQL-Like 中间表示设计, 但针对政务场景做了两方面适配: 一是在推理链条中保留了 LA-Schema 的逻辑增强信息, 使分步推理能够参考领域知识; 二是引入了类 SQL 中间表示, 允许模型先构建查询骨架再填充语法细节, 降低了一次性生成完整 SQL 的复杂度。其完整流程如算法3.3所示。

算法中, 渐进推理指令 BuildCoTInstr() 要求模型在单次生成中按照表3-1所定义的结构化格式, 以自回归方式依次输出意图分析 (reason)、涉及列 (columns)、筛选值 (values)、SELECT 内容以及 SQL-like 骨架共五个部分, 前序输出自然成为后续生成的上下文, 形成递进式的推理链。随后, 系统将生成的 SQL-like 骨架作为上下文, 再次调用大语言模型补充完整的 JOIN 条件和语法细节, 生成最终可

算法 3.3: 渐进分治生成算法

Input: 用户查询 Q , LA-Schema 增强模式 S^* , 动态样例 $F_u = \{f_1, \dots, f_k\}$,
采样数 n_c , 大语言模型 LLM

Output: 候选 SQL 集合 $\mathcal{C}_{pd}$

- 1 初始化: 候选集合 $\mathcal{C}_{pd} \leftarrow \emptyset$, 提示 $P \leftarrow \emptyset$;
 // 构建提示模板
- 2 $P \leftarrow P \oplus \text{FormatCoTShot}(F_u)$; // 拼接 $\langle \text{Query}, \text{CoT}, \text{SQL} \rangle$ 格式示例
- 3 $P \leftarrow P \oplus S^*$; // 拼接 LA-Schema 增强模式
- 4 $P \leftarrow P \oplus \text{BuildCoTInstr}() \oplus Q$; // 拼接渐进推理指令与用户查询
 // 多次采样生成候选 SQL
- 5 **for** $i \leftarrow 1$ **to** n_c **do**
 // 意图分析 $\rightarrow$ 涉及列与值 $\rightarrow \text{SELECT} \rightarrow \text{SQL-like}$
 6 $(\text{reason}_i, \text{cols}_i, \text{vals}_i, \text{sel}_i, \hat{y}'_i) \leftarrow \text{LLM}(P, \text{temperature} > 0)$;
 7 $\hat{y}_i \leftarrow \text{LLM}(P, \hat{y}'_i)$; // 基于 SQL-like 生成最终 SQL
 8 $\mathcal{C}_{pd} \leftarrow \mathcal{C}_{pd} \cup \{\hat{y}_i\}$;
9 **end**
- 10 **return** $\mathcal{C}_{pd}$

执行的 SQL 查询。动态少样本示例以完整的 $\langle \text{Query}, \text{CoT}, \text{SQL} \rangle$ 三元组呈现, 为模型提供渐进推理的范式参考。生成阶段同样在非零温度下执行 n_c 次独立采样, 产生多样化的候选集合 $\mathcal{C}_{pd}$ 。

该生成器的核心优势在于对复杂查询的处理能力。当查询涉及多层嵌套逻辑、复杂的条件组合或跨表关联时, 分步推理机制能够引导模型逐步构建查询结构, 避免因一步到位生成长 SQL 而导致的逻辑遗漏或结构错误。同时, 渐进生成器输出的结构化推理过程本身也具有可解释性, 有助于后续的错误分析和结果追溯。

此外, 渐进分治生成器与动态样例库之间存在正向反馈关系。当该生成器产生的候选 SQL 经判别后被确认为正确答案时, 其完整的 $\langle \text{Query}, \text{CoT}, \text{SQL} \rangle$ 输出可作为新的高质量样例纳入动态样例库, 为后续相似问题的处理提供更精准的参考。

3.6 基于执行反馈的查询修复

无论是逻辑映射生成器还是渐进分治生成器, 其产生的 SQL 候选集在某些情况下不可避免地存在逻辑或语法错误^[31,36], 这些错误会导致查询无法正确执行或返回空结果。为提升候选集的整体质量, 本文引入了一个基于执行反馈的查询修复模块, 作为候选生成后、判别选择前的鲁棒性增强环节。

在实际政务查询场景中, 常见的 SQL 错误类型包括: (1) 字段名不存在或拼写错误, 通常由模式链接阶段的遗漏或大语言模型的幻觉引起; (2) 表连接关系错误, 如遗漏必要的 JOIN 条件或使用了错误的连接键; (3) SQL 语法错误, 如括

号不匹配、关键字使用不当等；（4）聚合逻辑错误，如 GROUP BY 子句缺失必要字段或聚合函数使用不当。

查询修复器的工作机制基于自反思（Self-Reflection）方法^[82]。整个过程如图3-3所示。对于候选集中的每条 SQL 查询，系统首先在目标数据库上执行该查询，捕获执行结果或错误信息。若执行成功则保留该候选；若执行失败（如语法错误），则将执行器的反馈信息包括具体的错误描述以及原始用户问题、LA-Schema 信息一并构造为修复提示，送入大语言模型进行反思与修复。修复后的 SQL 会再次执行以验证其有效性。




图 3-3 查询修复流程图


为避免无限迭代带来的效率损耗和不收敛风险，修复过程设置了最大尝试次数 β （本文设定 $\beta = 3$ ）。当满足以下任一条件时，修复过程终止：（1）修复后的 SQL 执行成功；（2）达到最大尝试次数 β 。若修复在 β 次尝试后仍未成功，则保留最后一次修复的结果或标记该候选为不可用，在后续判别阶段予以排除。

查询修复器的引入有效降低了候选集中的无效查询比例，为后续的候选判别模块提供了更高质量的输入，从而间接提升了最终查询结果的准确率。


3.7 候选判别模型

经过异构候选生成与查询修复后，系统可为每个用户问题构建包含 $2n_c$ 个候选 SQL 的查询池。本节的目标是从该候选集中可靠地选出最终正确的 SQL 查询。

现有许多 Text-to-SQL 方法采用候选查询的一致性投票（Self-Consistency）策略，以得票最多的结果作为最终输出^[33]。然而，在复杂业务查询场景中，最一致的答案并不总是正确答案^[31]，其一致性选择策略与上界精度存在一定的性能差距。为此，本文构建选择智能体 $Agent_s$ ，并将候选选择建模为配对偏好判别问题。具体而言， $Agent_s$ 以用户问题、辅助提示信息、相关增强模式以及一对候选 SQL 为输入，判断两者中哪一个更可能正确，再通过两两比较与得分聚合确定最终输出。整体流程如图3-4所示。



(a) 离线训练



(b) 在线推理

图 3-4 候选判别整体流程

3.7.1 训练样本构建

判别模型的训练数据来源于在训练集上运行候选生成模块所得到的候选 SQL 集合。对于训练集中的每个问题 Q_u ，系统首先利用两个异构生成器产生 $2n_c$ 个候选 SQL，并在目标数据库上执行所有候选查询。设标准 SQL 的执行结果为 R_u^* ，候选 c_k 的执行结果为 R_k 。系统依据执行结果对候选进行聚类，将执行结果相同的候选划分至同一簇，再将各簇对应的执行结果与 R_u^* 进行比较：若二者一致，则该簇记为正确簇；否则记为错误簇。

在同时存在正确簇与错误簇的情况下，系统从两类簇中抽取候选，构造配对训练样本：

$$T_{ij} = (Q_u, H_u, c_i, c_j, S_{ij}^*, y_{ij}), \quad (3-8)$$

其中， Q_u 表示用户问题， H_u 表示辅助提示信息， c_i 与 c_j 表示两个待比较的候选 SQL， S_{ij}^* 表示 c_i 和 c_j 所涉及增强数据库模式的并集， $y_{ij} \in \{0, 1\}$ 为监督标签。当 c_i 来自正确簇且 c_j 来自错误簇时，记 $y_{ij} = 1$ ；反之记 $y_{ij} = 0$ 。

在样本构建过程中重点挖掘高价值负例。所谓高价值负例，是指执行结果与正确答案接近、但查询逻辑存在关键偏差的错误 SQL，例如筛选条件边界不同、聚合范围不一致或连接关系错误等。相较于随机负例，这类样本更能反映真实业务场景中的判别难点。对于训练集中未能生成正确候选的问题，本文仅在离线样本构造阶段引入标准 SQL 的执行结果，用于引导生成器产生更多与正确答案相似但不完全相同的错误候选，从而提升高价值负例的比例；该信息不作为判别模型在线推理时的输入，以避免信息泄漏。

3.7.2 判别模型训练

系统以 Qwen-8B 为基础模型构建选择智能体 Agent_s ，并采用指令式监督微调方式^[83](Instruction Supervised Fine-Tuning, ISFT) 进行训练。对于每个训练样本 T_{ij} ，系统将用户问题 Q_u 、辅助提示信息 H_u 、模式并集 S_{ij}^* 以及候选 SQL(c_i, c_j) 按统一模板组织为输入序列，要求模型输出二元判别结果，以表示两者中哪一个更可能为正确查询。由此， Agent_s 学习的是如下条件偏好概率：

$$p_\theta(y_{ij} = 1 \mid Q_u, H_u, S_{ij}^*, c_i, c_j), \quad (3-9)$$

其中 θ 表示大模型经微调后的模型参数。

训练目标采用二分类交叉熵损失函数：

$$\mathcal{L}_{\text{pair}} = -y_{ij} \log p_\theta(y_{ij} = 1 \mid T_{ij}) - (1 - y_{ij}) \log p_\theta(y_{ij} = 0 \mid T_{ij}). \quad (3-10)$$

考虑到高价值负例对模型判别能力的提升更为显著, 本文进一步引入样本权重 w_{ij} , 得到总体优化目标:

$$\mathcal{L} = \sum_{(i,j)} w_{ij} \mathcal{L}_{\text{pair}}. \quad (3-11)$$

其中, 对语义接近但逻辑错误的高价值负例赋予更高权重, 以增强模型对细微差异的敏感性。为兼顾训练效率与模型性能, 本文采用参数高效微调策略对大模型进行训练, 使其学习候选 SQL 之间的相对优劣关系且不丢失基础模型理解能力。

3.7.3 配对判别与最优候选选择

在线推理阶段, 系统基于配对比较与得分聚合机制, 从候选集 $C = \{c_1, c_2, \dots, c_{2n_c}\}$ 中选出最终 SQL, 其完整流程如算法3.4所示。

算法 3.4: SQL 候选集选取算法

Input: 候选集 $C = \{c_1, c_2, \dots, c_{2n_c}\}$, 用户问题 Q_u , 目标数据库 DB , 增强数据库模式 S^* , 选择智能体 Agent_s

Output: 最佳 SQL 查询 c_f

```

1 foreach  $c_i \in C$  do
2   |  $\text{score}_i \leftarrow 0$ ;
3 end
4 foreach  $(c_i, c_j) \in C \times C$  且  $i \neq j$  do
5   | if  $\text{ans}(c_i, DB) = \text{ans}(c_j, DB)$  then
6   |   |  $\text{winner} \leftarrow i$ ; // 结果一致时, 无需调用判别模型
7   | else
8   |   |  $S_{ij}^* \leftarrow \text{SchemaUnion}(c_i, c_j, S^*)$ ;
9   |   |  $\text{winner} \leftarrow \text{Agent}_s(Q_u, S_{ij}^*, c_i, c_j)$ ;
10  | end
11  |  $\text{score}_{\text{winner}} \leftarrow \text{score}_{\text{winner}} + 1$ ;
12 end
13  $c_f \leftarrow \arg \max_{c_i \in C} \text{score}_i$ ;
14 return  $c_f$ 

```

对于任意两个不同候选 (c_i, c_j) , 系统首先在目标数据库 DB 上执行二者并比较执行结果。若 $\text{ans}(c_i, DB) = \text{ans}(c_j, DB)$, 则说明二者在功能上等价, 无需调用判别模型; 若二者执行结果不同, 则构造其相关增强模式并集 $S_{ij}^* = \text{SchemaUnion}(c_i, c_j, S^*)$, 并调用 Agent_s 进行二元判别。考虑到输入顺序可能影响模型输出, 系统对每一对

候选同时比较 (c_i, c_j) 与 (c_j, c_i) 两个方向，并将胜者分别累加得分，从而减轻顺序偏差。最终，系统选择累计得分最高的候选作为输出：

$$c_f = \arg \max_{c_i \in C} \text{score}_i. \quad (3-12)$$

若出现平局，系统优先选择执行成功且返回非空结果的候选；若仍无法区分，则进一步选择 SQL 语句长度较短的候选作为最终结果。通过上述机制，本文将候选选择由一致性投票转化为基于配对偏好的全局竞争过程，从而更有效地利用候选间的细粒度差异信息，提高最终 SQL 的选取准确率。

3.8 实验与结果分析

本章首先介绍实验设置，包含数据集构建与选用、评估指标定义、对比模型。然后针对政务领域数据集上进行对比实验、消融实验、异构协同与判别分析及效率分析。最后本文还在公共数据集 BIRD^[19]、Spider^[18] 上进行实验，以评估本文方法在泛用数据集上的适用性与稳健型。

3.8.1 数据集构建与实验设置

为全面评估本文方法在政务领域的有效性，实验采用自建政务数据集进行评估。鉴于政务数据的隐私敏感性，本文基于“多源采集—逻辑注入—混合标注”的流程构建了面向政务场景的 Text-to-SQL 评测数据集。

数据集的构建流程分为三个阶段：

(1) **多源数据采集与脱敏**。数据来源于某市经济开发区政务平台，原始数据涵盖财政预算、公共资源和政务项目三个领域的 5 个数据库，共计 33 张数据表。为保障数据安全，对涉及个人隐私的敏感信息（如身份证号、联系方式等）进行了加盐哈希的严格脱敏处理，确保数据在技术上不可逆向还原。

(2) **基于领域知识库的逻辑注入**。通过人工梳理 20 余个核心业务指标，将包括预算执行率、同比增长率、集中采购率等在内的隐性业务逻辑显性化地录入标注元数据中。确保数据集包含足够多的需要领域知识。

(3) **人机协同混合标注**。问答对的生成采用人机协同的方式：首先利用 Qwen 大语言模型^[9]根据原始数据库模式生成种子问题和初始 SQL，然后由具备政务业务背景的标注人员对生成结果进行核验和纠正，确保问题的自然性和 SQL 的正确性。

最终构建的数据集包含 480 条高质量的自然语言问题—SQL 查询对，按照 7:3 的比例划分为训练集和测试集。训练集用于候选判别模型微调，而在训练样本构

建阶段产生共计近 5000 个元组。测试集用于最终端到端性能评估。数据集中约 38.5% 的问题涉及复杂查询（包括多表连接、嵌套子查询、复杂聚合等）。数据集统计信息如表3-3所示。

表 3-3 政务数据集 GovSQL 统计信息

划分	领域数	数据库数	数据表数	字段数	问题-SQL 对数	复杂查询占比/%
训练集	3	5	33	217	336	37.8
测试集	3	5	33	217	144	40.3
合计	3	5	33	217	480	38.5

在实验配置方面，本文使用 Qwen3-Coder-30B-A3B-Instruct^[9]作为基础调用大语言模型，用于模式链接、候选生成和查询修复等主要环节；使用 Qwen3-8B^[9]作为候选判别模型的基础模型进行微调训练。

存储引擎使用 Milvus 作为向量库构建存储，PostgreSQL 作为领域知识库，并联合使用 Milvus 和 PostgreSQL 实现动态样例库。在工程上使用 Redis 作为热点缓存工具，提高调用性能。联合使用 Milvus、PostgreSQL 作为向量库、知识库以及样例库的存储引擎。

实现设置上，动态样例检索的样本数 n_f 设为 5，此外样例库实验评估阶段关闭在线增量更新，避免测试数据泄漏。模式链接阶段，候选列的召回数 k 设为 10。除候选生成外的其他 LLM 调用阶段温度参数 $temperature = 0.3$ 。而在候选生成阶段，每个生成器在温度参数 $temperature = 0.7$ 的设置下各采样生成 $n_c = 10$ 个候选 SQL。

3.8.2 评估指标与对比基线

本文采用执行准确率（Execution Accuracy, EX）作为主要评估指标。EX 通过比较预测 SQL 查询与参考 SQL 查询在目标数据库上的执行结果来判定正确性：

$$EX = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\text{ans}(SQL_i^{\text{pred}}, DB) = \text{ans}(SQL_i^{\text{gold}}, DB)] \quad (3-13)$$

其中 N 为测试集样本数， $\text{ans}(SQL, DB)$ 表示 SQL 在数据库 DB 上的执行结果。EX 指标关注的是查询的功能等价性而非形式一致性，即允许 SQL 在写法上存在差异，只要执行结果相同即视为正确。

此外，本文在异构协同与候选判别分析和效率分析中还使用了以下辅助指标：判别模型的二分类准确率以及端到端平均响应时延。

对比基线分为以下三类：

(1) **开源基础大模型**。该类基线采用零样本（zero-shot）Text-to-SQL 提示直接生成 SQL，不引入任何额外的优化策略，旨在衡量大语言模型本身的 SQL 生成能力下限。具体包括：DeepSeek-V3^[10]，本地部署，采用零样本提示生成 SQL；Qwen3-Coder-30B-A3B-Instruct^[9]，本地部署，同样采用零样本提示生成 SQL。

(2) **基于提示词的无微调方法**。该方法通过精心设计的提示工程策略提升 SQL 生成质量，无需对模型参数进行微调。具体包括：DAIL-SQL^[29]，通过为不同问题检索语义相似的问题-SQL 对作为少样本示例，引导大语言模型生成 SQL；OpenSearch-SQL^[33]，通过动态上下文学习与一致性对齐策略，以多智能体协同的方式生成 SQL；Alpha-SQL^[34]，基于蒙特卡洛树搜索建模 Text-to-SQL 生成过程，配合动态生成推理动作与自监督奖励函数进行搜索式 SQL 生成。

(3) **基于监督微调的方法**。该方法通过在 Text-to-SQL 数据上对模型进行监督微调，使模型习得面向 SQL 生成的专用能力。具体包括：XiYan-SQL^[32]，融合监督微调与上下文学习，并使用 M-Schema 增强模式理解，以多生成器集成的方式生成 SQL；CHASE-SQL^[31]，通过多路径候选生成器产生多样化的 SQL 候选，并使用经偏好优化微调的选择代理进行候选判别；OmniSQL^[35]，通过自动化合成百万级高质量 Text-to-SQL 数据及思维链标注，基于开源大模型进行大规模监督微调。

为保证对比的公平性，上述基线方法（除开源基础大模型和 OmniSQL 外）均使用与本文相同的 Qwen3-Coder-30B-A3B-Instruct 作为基础 LLM。

3.8.3 总体性能对比

表3-4展示了各方法在政务数据集上的执行准确率对比结果。本文方法取得了 91.47% 的执行准确率，显著优于所有对比基线。

表 3-4 不同 Text-to-SQL 方法在政务数据集上的性能对比

类别	方法	执行准确率/%
开源基础大模型	DeepSeek-V3	64.90
	Qwen3-Coder-30B-A3B-Instruct	69.17
基于提示词无微调	DAIL-SQL	74.42
	OpenSearch-SQL	76.51
	Alpha-SQL	80.27
基于监督微调	OmniSQL	71.56
	CHASE-SQL	81.33
	XiYan-SQL	<u>83.83</u>
本文方法	Ours	91.47

从结果中可以得出以下分析：

以 DeepSeek-V3 和 Qwen3-Coder 为代表的零样本方法,其准确率普遍处于 65% 至 70% 之间。分析发现,这类方法虽然具备一定的 SQL 语法生成能力,但在面对政务场景中晦涩的物理列名和复杂的业务指标时,极易产生“语义幻觉”,即模型臆造了不存在的列名或使用了错误的计算逻辑,无法准确映射底层的业务规则。

DAIL-SQL 和 Alpha-SQL 等基于提示词工程的方法通过优化上下文样本选择在一定程度上提升了性能,其中 Alpha-SQL 达到了 80.27%。然而,这类方法本质上仍属于隐式推理范式,模型必须在有限的上下文窗口内同时完成语义理解和逻辑推演。在处理高嵌套、跨表计算等复杂政务查询时,上下文中的有效信息容易被稀释,推理链条断裂的概率显著增加。

XiYan-SQL 和 CHASE-SQL 等包含微调组件的方法表现相对优异,分别达到了 83.83% 和 81.33%。这表明监督微调在特定领域数据集上确实能带来增益效果。但即便经过微调,如果模型不具备实时的领域逻辑增强支撑,在面对政务业务中涉及复杂计算公式和动态变化的业务规则时,仍然难以突破 85% 的准确率瓶颈。

相比之下,本文方法相较于最强基线 XiYan-SQL 实现了 7.64 个百分点的提升,相较于 CHASE-SQL 实现了 10.14 个百分点的提升。这一显著改善主要归因于三方面的协同作用: LA-Schema 的逻辑增强机制有效缓解了政务领域的语义幻觉问题;异构协同生成策略扩大了候选池的多样性和覆盖度;微调判别模型则从多样化的候选中精准筛选出最优答案。

3.8.4 消融实验

为深入探究系统中各核心模块的有效性,本文设计了消融实验。通过在完整模型 (Full Model) 的基础上分别移除或替换关键模块,观察其在政务数据集上的执行准确率变化。实验结果如表3-5所示,移除任何一个模块均会导致性能下降,证明了各模块的不可或缺性。

w/o HNSW。在数据预处理阶段,若不使用 HNSW 索引进行向量值检索,而直接采用语义匹配的单阶段值检索,执行准确率降至 89.32%。这证明了 HNSW 索引在处理大规模政务元数据时,能够更高效且精准地召回与查询相关的数据库值。

w/o Dynamic Few-shot。移除动态样例库后,模型仅依赖固定的提示词模板,准确率下降 6.16% 至 85.31%。这表明政务查询具有高度的领域多样性,通过动态检索语义相似的少样本样例,能够为模型提供关键的上下文生成参考,增强系统对特定业务语境的自适应能力。尤其是 $\langle \text{Query}, \text{CoT}, \text{SQL} \rangle$ 格式的样例比传统的 $\langle \text{Query}, \text{SQL} \rangle$ 格式能够提供更丰富的推理线索。

表 3-5 移除系统关键模块的消融实验性能比较

模型方法	执行准确率/%	ΔEX /%
Full Model	91.47	-
w/o HNSW	89.32	-2.15
w/o Dynamic Few-shot	85.31	-6.16
w/o LA-Schema	84.62	-6.85
w/o Logical Generator	87.93	-3.54
w/o DC Generator	88.88	-2.59
w/o Query Fixer	89.24	-2.23
w/o Selection Agent	86.12	-5.35

w/o LA-Schema. 当系统不使用逻辑增强模式而是采用传统的 DDL Schema 时, 性能出现最大的下滑, 降幅达 6.85%。值得注意的是, 该配置下的准确率 (84.62%) 与最强基线 XiYan-SQL (83.83%) 接近, 说明在去除 LA-Schema 后系统的性能优势几乎消失。这充分证明了在政务垂直领域, 物理字段名的隐晦性和业务逻辑的复杂性是 SQL 生成的核心瓶颈, 而 LA-Schema 通过显式注入业务等先验信息, 将复杂的逻辑演算简化为模式调用, 是系统高性能的核心保障。

w/o Logical Generator & w/o DC Generator. 分别去除逻辑映射生成器和渐进分治生成器后, 执行准确率分别下降 3.54% 和 2.59%。逻辑映射生成器的贡献略大于渐进分治生成器, 这反映了政务数据集中包含较多需要领域逻辑映射的业务指标查询。

w/o Query Fixer. 去除查询修复器后, 准确率下降 2.23% 至 89.24%。虽然修复器的单独贡献相对较小, 但其通过基于执行反馈的迭代修正机制, 有效提升了候选集中可执行查询的比例, 为后续判别模型提供了更高质量的输入。

w/o Selection Agent. 若不使用基于执行反馈的选择智能体进行候选判别, 而是采用一致性多数投票策略, 准确率下降 5.35% 至 86.12%。这说明多数投票无法充分感知 SQL 的执行质量, 而选择智能体能够通过执行反馈识别出语义虽不一致但逻辑正确的潜在答案, 显著提升了异构候选冲突时的容错率。

3.8.5 异构协同与候选判别分析

为深入剖析异构协同生成机制与候选判别模型这一核心创新的有效性, 从生成器独立性能、判别模型精度、候选池多样性三个维度设计了系统性的专项实验。

生成器性能分析

为揭示各生成器的独立贡献, 本文在候选判别前对每个生成器的单候选生成能力进行了评估。即将每个生成器生成单条候选 SQL 的准确率与零样本 CoT 基线

进行对比，同时考察查询修复器对各生成器的增益效果。结果如图3-5所示。




图 3-5 各生成器单候选生成性能对比

从结果中可以得出以下分析。首先，两个生成器的单候选性能均显著优于零样本 CoT 基线，逻辑映射生成器提升了 9.45 个百分点，渐进分治生成器提升了 8.07 个百分点，验证了本文所设计的生成策略在引导大语言模型进行 SQL 生成方面的有效性。其中逻辑映射生成器略优于渐进分治生成器，这主要归因于政务数据集中包含大量可直接利用 LA-Schema 预置逻辑块的业务指标查询。其次，查询修复器对所有生成方法均带来了约 2%~3% 的性能增益，表明基于执行反馈的迭代修复机制能够有效纠正语法错误和执行异常，提升候选的整体可用性。

判别模型分析

候选判别模型的二分类准确率直接决定了从候选池中选出正确答案的能力。本文对不同选择策略的判别精度进行了对比实验，在配对比较中仅统计一个候选正确、另一个候选错误的高价值情况。结果如表3-6所示。

表 3-6 不同选择策略的二分类判别准确率

选择模型	二分类准确率/%
Qwen3-Coder-30B（未微调）	59.38
Qwen3-8B（未微调）	55.62
Qwen3-8B（微调，本文方法）	72.85

实验结果表明，未经微调的大语言模型在配对判别任务上的准确率仅略高于随机猜测水平（55%~59%），这是因为异构生成器产生的候选 SQL 之间往往仅存在细微差异（如 WHERE 条件中的一个值不同、聚合范围略有差别等），未微调模型难以捕获这些关键区分特征。相比之下，经过在训练集上产生的高价值正负样本对进行微调后，Qwen3-8B 的判别准确率提升至 72.85%，提升了 17.23 个百分点。

这一结果与 CHASE-SQL^[31]中的发现一致，即配对选择任务需要通过监督微调使模型学习到候选 SQL 之间细粒度的语义偏好。

候选池多样性与生成器互补性分析

本文对两个生成器在候选池层面的互补性进行了深入考察。对于测试集中的每个问题，分别统计仅逻辑映射生成器产生正确候选、仅渐进分治生成器产生正确候选以及两者均产生正确候选的情况。如图3-6所示。




图 3-6 生成器在测试集覆盖统计

在 144 个测试样本中，有 21 个问题（14.6%）仅被逻辑映射生成器覆盖，16 个问题（11.1%）仅被渐进分治生成器覆盖，102 个问题（70.8%）被两个生成器同时覆盖，仅有 5 个问题（3.5%）未被任一生成器产生的候选所覆盖。

逻辑映射生成器独占的 21 个正确案例以包含预定义业务指标的标准化查询为主，涉及需要精确公式调用的问题。渐进分治生成器独占的 16 个正确案例则集中在结构复杂的查询上，包括多层嵌套子查询、跨表关联聚合等场景。两种推理范式在查询类型上的互补性是异构协同策略有效的根本原因。

3.8.6 效率分析

表3-7展示了本文方法各模块的平均耗时、时间占比、LLM 调用次数及 Token 消耗情况。

端到端单条查询存在波动，累计需 7~24 次 LLM 调用，Token 消耗范围为 12500~43000 个，具体取决于候选修复的轮次以及生成器生成的多样性。

其中候选生成环节占据了最大的时间比重（42.6%），平均耗时 17.1 秒，这主要是由于两个生成器各需采样多个候选并涉及较长的提示序列，尽管双路并行执

表 3-7 各模块效率分析（平均单样本）

模块	平均耗时/s	占比/%	平均 LLM 调用/次	Token 消耗/个
模式链接	7.8	19.5	3	3000–8000
候选生成（双路并行）	17.1	42.6	3	9000–20000
查询修复	3.8	9.5	0–3	0–6000
候选判别	10.7	26.7	1–15	500–9000
其他（SQL 执行等）	0.7	1.7	0	0
端到端总计	40.1	100.0	7–24	12500–43000

行已有效压缩了该环节的绝对耗时。每次候选生成固定调用 3 次 LLM（逻辑映射生成器 1 次、渐进分治生成器 2 次-均为线程数为 10 的并发调用），Token 消耗为 9000~20000 个，是所有模块中最高的。候选判别环节耗时 10.7 秒（26.7%），是第二大耗时模块。该环节需要对候选对执行多轮配对比较，LLM 调用次数为 1~15 次，波动较大的原因在于执行结果一致的候选对可直接跳过模型判别，而执行结果不同的候选对则需逐对调用选择智能体，Token 消耗为 500~9000 个。模式链接环节耗时 7.8 秒（19.5%），需 3 次 LLM 调用，其开销主要来自实体提取、向量检索及大语言模型的列相关性评估，Token 消耗为 3000~8000 个。查询修复环节耗时 3.8 秒（9.5%），LLM 调用次数为 0~3 次，Token 消耗为 0~6000 个。当所有候选 SQL 均执行成功时无需触发修复流程，调用次数和 Token 消耗均为零；当存在执行失败的候选时，最多进行 3 轮迭代修复。

对于政务数据查询这一非实时交互的应用场景而言，40 秒左右的响应时间处于可接受范围内。在实际部署中，候选生成的并行化策略（两个生成器同时运行且多线程生成候选 SQL）已将该环节的耗时控制在合理水平；同时 SQL 执行结果的缓存大大提高了使用性能。若需进一步降低延迟，可考虑减少每个生成器的采样数量（如降低至 5 或者 3），以在准确率与响应速度之间取得更优的折中。

3.8.7 公共数据集实验结果

BIRD 和 Spider 是两个广受认可的跨域数据集，分有不重叠的训练集、开发集、测试集。BIRD 包含来自 95 个大型数据库的超过 12,751 个独特的问题-SQL 对，涵盖 37 个专业领域，其数据库设计模仿现实世界场景，具有杂乱的数据行和复杂的模式。Spider 包含 10,181 个问题和 5,693 个独特的复杂 SQL 查询，涉及 200 个数据库，覆盖 138 个领域。

为评估本文方法在泛用场景下的适用性与稳健性，本文在两个主流的跨领域公共 Text-to-SQL 基准数据集上进行了实验：BIRD^[19]开发集（BIRD-dev）和 Spider^[18]测试集（Spider-test）。在公共数据集实验中，本文方法未使用政务领域知识

库，动态样例库也替换为基于目标数据集训练集构建的通用样例库，以确保评测条件与其他基线方法保持一致。各方法的执行准确率对比结果如表3-8所示。

表 3-8 公共数据集上的性能对比

方法	使用模型	BIRD/%	Spider/%
DeepSeek-V3	DeepSeek-V3	63.80	85.80
Qwen3-Coder	Qwen3-Coder-30B-A3B-Instruct	67.33	88.27
DAIL-SQL	GPT-4	54.76	86.60
OpenSearch-SQL	GPT-4o	69.30	87.10
Alpha-SQL	Qwen2.5-Coder-32B	69.70	-
XiYan-SQL	GPT-4o + Qwen2.5-Coder-32B	73.34	89.65
CHASE-SQL	Gemini-1.5-Pro + Gemini-1.5-Flash	74.90	87.60
OmniSQL	Qwen2.5-Coder-32B	67.00	89.80
本文方法	Qwen3-Coder-30B-A3B-Instruct + Qwen3-Flash-8B	71.23	89.25

从结果中可以得出以下分析：

(1) 在 **BIRD-dev** 上，本文方法取得了 71.23% 的执行准确率，仅次于 CHASE-SQL (74.90%) 和 XiYan-SQL (73.34%)。与政务数据集上的显著领先不同，本文方法在 BIRD 上未能超越这两个强基线，其核心原因在于：BIRD 数据集包含 95 个不同领域的数据库，本文的 LA-Schema 机制在缺乏目标领域知识库支撑的情况下无法发挥其领域逻辑增强的核心优势。而 CHASE-SQL 和 XiYan-SQL 针对通用场景设计了更具普适性的生成策略（如 CHASE-SQL 的查询执行计划 CoT 和 XiYan-SQL 的多生成器集成），在无领域先验的条件下表现更为稳健。尽管如此，本文方法仍显著优于 DAIL-SQL (+16.47%)、OmniSQL (+4.23%) 等方法，且相较于使用相同基础模型的 Qwen3-Coder 零样本基线提升了 3.90 个百分点，表明异构协同生成与微调判别机制本身在通用场景下同样具备增益能力。

(2) 在 **Spider-test** 上，本文方法取得了 89.25% 的执行准确率，仅次于 OmniSQL (89.80%) 和 XiYan-SQL (89.65%)，超过了 CHASE-SQL (87.60%)。Spider 数据集的查询结构相对规范、领域语义歧义较少，各方法的性能差距较 BIRD 上更为收窄。本文方法在未针对 Spider 做任何特定适配的情况下展现竞争力表现，说明本文设计的异构候选生成框架和配对判别机制具有较好的跨数据集泛化能力。值得注意的是，OmniSQL 通过百万级合成数据的大规模监督微调获得了最高性能，而本文方法仅对判别模型进行了小规模微调，在效率上更具优势。

(3) 综合来看，本文方法在公共数据集上表现出稳定的竞争力，验证了异构协同生成与微调判别这一技术框架的通用性。同时，本文方法在政务数据集上的领先优势 (91.47%) 与公共数据集上的性能差距也从侧面印证了 LA-Schema 领域逻

辑增强机制的核心价值，即在具备领域知识支撑的垂直场景中，本文方法能够充分发挥知识驱动的优势，实现显著超越；而在缺乏领域知识的通用场景中，方法仍能依靠异构生成与判别机制保持主流水平。

3.9 本章小结

本章针对政务数据查询中业务语义模糊、计算逻辑隐含及查询结构复杂等挑战，提出了基于逻辑增强与异构协同的 Text-to-SQL 方法。该方法通过构建结构化领域知识库并以 LA-Schema 形式显式注入数据库模式，提升政务领域的业务理解能力；通过逻辑映射与渐进分治双路径异构生成机制，平衡了高频标准需求与低频复杂长尾需求；通过微调二分类判别模型与执行反馈修复机制，提升了最终查询的准确性与鲁棒性。最终在政务数据集和公开数据集验证了本章所提模型的有效性。为构建智能问数系统提供了核心技术支持。

第4章 基于分析规划与查询增强的政务数据分析方法

4.1 引言

第三章围绕政务智能问数中的可靠取数问题，提出了基于逻辑增强与异构协同的 Text-to-SQL 方法，重点解决自然语言查询到结构化查询语句的准确映射问题。然而，在真实政务业务场景中，用户需求往往并不止于“查到数据”，而是进一步希望系统能够围绕查询结果完成趋势识别、横向比较、结构刻画和结论归纳等分析任务。因此仅有可靠的 SQL 生成能力仍不足以支撑完整的政务数据洞察。

基于此，本章聚焦于：如何在第三章可靠查询能力的基础上，将自然语言分析需求转化为结构化分析计划；如何将分析任务拆解为查询层与分析层两个相互协同但职责清晰的阶段；以及如何基于查询结果生成规范化的图表、表格和文字洞察。换言之，第三章解决查准，本章进一步解决围绕查询结果开展规范分析。

本章将分析过程定义为：给定自然语言分析需求 x 、目标数据库模式 S 、已构建的领域知识库 K 、动态样例库 F 、查询生成工作流 G_q 、分析算子库 O_a 以及可视化规则集合 $\mathcal{V}$ ，系统最终生成分析规划 A 和结果包 R ，使得分析结果与用户意图最大化一致，即：

$$(A^*, R^*) = \arg \max_{A \in \mathcal{A}, R \in \mathcal{R}} P(A, R \mid x, S, K, F, G_q, O_a, \mathcal{V}) \quad (4-1)$$

其中， $\mathcal{A}$ 表示候选分析规划集合， $\mathcal{R}$ 表示候选结果集合。为支撑上层应用展示与后续系统实现，本章将输出统一组织为

$$\text{ResultPackage} = \{\text{charts}, \text{tables}, \text{insights}, \text{logs}\} \quad (4-2)$$

其中 **charts** 表示图表文件或图表描述集合，**tables** 表示结构化分析表格结果，**insights** 表示文字洞察摘要，**logs** 表示执行状态与异常信息。

结合政务场景中的高频需求，本章将目标任务限定为四类典型分析类型，各类型的核心逻辑与适用场景如表4-1所示。

与查询任务相比，面向分析的结果生成面临三类挑战。其一，分析需求通常隐含指标、维度、时间粒度、统计口径和展示形式等多重约束，若缺乏中间规划过程，系统容易遗漏关键分析步骤；其二，若分析环节重新承担数据库理解与 SQL 生成任务，则会再次暴露 Schema 歧义、字段映射错误和逻辑幻觉等问题；其三，分析结果不仅要正确，还要展示规范，因此需要在方法层面形成统一的结果组织方式，而具体的服务部署等工程实现将在系统实现章节展开。

表 4-1 四类典型分析类型及其适用场景

分析类型	核心逻辑	适用场景
趋势分析	沿时间维度追踪指标的变化轨迹与演进规律	财政收入增减趋势、企业注册量波动、工单受理量走势等
对比分析	沿区域、部门、年份等维度对关键指标进行横向比较	不同区县经济指标差异、部门绩效对比、年度预算同比等
排名分析	按指定指标排序并识别头部与尾部对象	项目投资额排名、预算执行率排名、办件效率排名等
结构分析	计算整体内部各组成部分的占比与分布	财政支出结构、产业类型分布、收入来源构成等

基于上述考虑，本章以“分析规划、查询增强、算子生成、规范输出”为总体思路展开研究。首先，通过构建结构化中间表示 AP-Schema，将开放式分析需求转化为面向执行的分析规划；第二，通过查询增强的任务分解机制，将分析任务拆分为查询层操作与分析层操作，确保复杂业务口径仍由数据查询模块统一处理；第三，引入轻量分析算子库与可视化规则，在查询结果上完成稳定的分析结果生成；最后，将输出统一组织为标准化结果包，为后续的系统实现提供清晰的方法基础。通过上述设计，数据查询模块与数据分析模块共同构成从可靠取数到规范分析的完整技术链路。

4.2 总体框架设计

基于上述目标，本文设计了一个面向政务洞察的分析规划与查询增强协同框架。其整体流程由需求解析、AP-Schema 构建、查询需求投影、取数调用、分析算子执行以及结果组织六个阶段组成。与第三章的 Text-to-SQL 流程相比，本章不再重新研究 SQL 生成，而是将第三章的方法作为标准化数据获取子模块嵌入分析流程中，实现“先查准、再分析”的层级协同。

框架的核心数据流可表示为：

$$\begin{cases} A = \text{BuildPlan}(x, K), \\ Q_A = \pi_q(A), P_A = \pi_a(A), \\ D = G_q(x, Q_A; S, K, F), \\ R = \text{Generate}(P_A, D; \mathcal{O}_a, \mathcal{V}) \end{cases} \quad (4-3)$$

其中， A 表示由分析规划模块生成的 AP-Schema； $\pi_q(\cdot)$ 表示从 AP-Schema 中投影出取数需求子结构的操作； $\pi_a(\cdot)$ 表示投影出分析层操作与展示要求的操作； S 为

目标数据库模式； K 为3.3.2中构建的领域知识； F 为3.3.3构建的动态样例库； G_q 表示对第三章查询生成管线与数据库执行过程的上层抽象。具体而言，系统首先通过模板化组装函数将原始分析需求 x 与查询投影 Q_A 合成为受约束的查询子问题 $x_q = \text{Assemble}(x, Q_A)$ ，再结合目标数据库模式 S 、领域知识库 K 和动态样例库 F ，由数据查询方法（3.4至3.7）完成模式链接、候选生成与最优 SQL 查询 c_f 选择，最后在目标数据库上执行 c_f 并封装返回结果； $\mathcal{D}$ 表示该管线返回的数据结果、字段元数据与执行状态； R 表示最终结果包。

整个框架如图4-1所示：




图 4-1 分析规划与查询增强协同数据分析框架图

需求解析阶段负责从用户输入中识别分析对象、指标、时间范围、分组维度和期望展示形式，为后续规划提供语义基础。

AP-Schema 构建阶段将自然语言需求转化为结构化分析表示，用于明确“分析什么”“通过哪些数据分析”“如何展示结果”三个核心问题。该中间表示是本章的关键方法载体，也是连接第三章查询方法与第五章系统实现的重要桥梁。

查询需求投影阶段从 AP-Schema 中抽取与数据获取相关的指标、维度、过滤条件、时间粒度和查询层操作，并调用查询生成管线完成可靠取数。

取数调用阶段依据 $x_q = \text{Assemble}(x, Q_A)$ 将受约束查询子问题送入第三章查询生成管线，以确保字段绑定、逻辑指标求解和 SQL 执行仍由查询模块统一完成。

分析算子执行阶段在获取到查询结果后，根据分析类型与任务要求，从轻量分析算子库中选择合适的操作链，对结果数据完成排序、占比、透视、标注等分析处理，并结合可视化规则生成规范化图表与表格。

结果组织阶段将图表、表格、摘要和日志统一封装为 ResultPackage，以便后续系统展示、日志记录和误差分析。

通过上述设计，本章的方法在保持大语言模型语义理解能力的同时，引入了

清晰的中间表示、稳定的任务分解机制和规范化的结果生成流程，从而应对政务场景下对可靠性、规范性与可落地性的综合要求。

4.3 分析规划构建

分析规划并非对用户需求的简单转写，而是将分析对象、统计口径、执行边界与展示要求统一编码为可验证的中间表示。为此，本节围绕 AP-Schema（Analysis Plan Schema）展开，依次说明其模式定义、字段约束与完备性校验机制，以及从自然语言需求到结构化规划实例的构建过程，从而为后续查询投影与分析算子编排提供统一基础。AP-Schema 的整个构建与约束机制过程如图4-2所示。




图 4-2 AP-Schema 构建与约束机制图

4.3.1 规划模式定义

为统一表达分析需求并为后续查询投影与算子编排提供结构化基础，本文引入分析规划模式 AP-Schema，并将其定义为：

$$\begin{cases} A = \langle T, M, D, \hat{F}, G, O_q, O_a, \hat{V}, \hat{S} \rangle, \\ T \in \{\text{trend, comparison, ranking, structural}\} \end{cases} \quad (4-4)$$

表4-2给出了 AP-Schema 各字段的语义定义。与原始自然语言需求相比，AP-Schema 将分析任务中的关键约束显式化，使后续的查询投影、分析算子组织和结果验证能够围绕同一结构化表示协同展开。

表 4-2 AP-Schema 字段定义

组成部分	符号	含义	典型取值
分析类型	T	任务所属的分析类别	trend、ranking 等
指标集合	M	待分析指标及其聚合方式	预 算 收 入/SUM、项 目 数/COUNT
维度集合	D	用于分组、对比或结构刻画的语义维度	区县、部门、时间、支出领域
筛选条件	$\hat{F}$	时间范围与对象过滤条件	年份 =2025、区县 $\in \{A,B\}$
分析粒度	G	时间或统计粒度	年度、季度、月度、类别级
查询层操作	O_q	取数阶段的口径与关联操作	同比口径、跨表关联
分析层操作	O_a	结果上的展示与整理操作	sort→topk→annotate
可视化规格	$\hat{V}$	图表类型与坐标映射要求	折线图、柱状图、饼图
摘要要求	$\hat{S}$	文字洞察需覆盖的要点	峰值月份、占比前三、最大增幅

4.3.2 约束与完备性

AP-Schema 的九个字段并非相互独立，而是存在由分析类型 T 驱动的结构性约束。不同的 T 取值对维度集合 D 、分析粒度 G 和默认可可视化类型 $\hat{V}$ 等字段提出了不同的最低要求，从而将后续生成过程约束在合理的决策空间内。表4-3列出了四类分析类型对关键字段的典型约束。

表 4-3 分析类型对 AP-Schema 关键字段的约束

T 分析类型	D 必须包含	G 典型取值	$\hat{V}$ 默认	O_a 常用算子
趋势分析	时间维度	月度/季度/年度	折线图	sort, annotate
对比分析	至少一个对比维度	按对比维度聚合	柱状图	pivot, sort
排名分析	排序维度	按维度聚合	横向柱状图	sort, topk
结构分析	分类维度	类别级汇总	饼图/堆叠柱	share, annotate

这些约束在规划生成阶段起到完备性校验的作用。例如，若系统识别出 $T = \text{trend}$ 却未在 D 中包含时间维度，则规划应视为不完备并触发补全；若识别出 $T = \text{structural}$ 却未发现任何分类维度字段，系统需要回溯至意图识别阶段重新提取维度信息。本文将该校验形式化为：

$$\text{Valid}(A) = \bigwedge_{c_i \in \mathcal{C}} c_i(A) \quad (4-5)$$

其中， $\mathcal{C}$ 表示由表4-3推导的约束规则集合。当 $\text{Valid}(A)$ 不成立时，系统将尝试从

用户输入中二次抽取缺失信息或使用领域知识推断默认值。

4.3.3 规划生成

AP-Schema 的构建过程本质上是从开放式自然语言分析需求到结构化规划表示的语义映射。该映射并非要求大语言模型自由输出分析结论，而是先通过固定槽位提示模板生成规划草案 $A^{(0)}$ ，再依次经过意图识别、槽位填充、操作分解与规格初始化四个子步骤，对草案中的字段进行解析、校验和补全，从而逐层完成对分析需求的结构化。

意图识别阶段负责确定分析类型 T 。系统通过大语言模型对用户输入执行语义解析，识别其中显式或隐式包含的分析意图线索，包括趋势词（“变化”“走势”“波动”）、比较词（“对比”“差距”“哪个更高”）、排序词（“排名”“前三”“最多”）和结构词（“占比”“构成”“分布”）。当输入中同时包含多类意图线索时，系统采用优先级规则进行消歧：若同时出现时间变化语义和对比语义，则优先判定为趋势分析（ $T = \text{trend}$ ），因为对比通常是趋势分析的附属展示而非独立任务。

槽位填充阶段负责从用户输入中提取 M 、 D 、 $\hat{F}$ 、 G 四个核心字段。该阶段结合领域知识库 $K = \{B, L, V\}$ 进行语义归一。具体而言，指标词通过业务术语映射 B 归一为标准业务指标及其默认聚合方式；时间范围和对象范围通过值域约束 V 确认取值合法性；分析粒度 G 根据时间词和分析类型联合推断。例如，当用户提出“分析近两年各区一般公共预算收入的月度趋势”时，“一般公共预算收入”先通过 B 归一为标准业务指标“一般公共预算收入/SUM”，而不在本阶段直接绑定到具体物理字段；“近两年”通过 V 映射为年份 $\in \{2024, 2025\}$ ，“月度”确定 $G = \text{month}$ 。后续在查询需求投影阶段，系统再将这些约束连同原始需求交由数据查询模块结合数据库模式 S 完成字段绑定与 SQL 生成。

操作分解阶段负责将用户需求中涉及的操作划分为查询层操作 O_q 与分析层操作 O_a 。其判断依据是：凡依赖数据库模式理解或改变统计口径的操作归入 O_q ，凡仅对已获取结果进行重组或展示的操作归入 O_a 。例如，上述需求中“并给出同比变化”涉及逻辑计算器 L 中预定义的跨年度计算公式，应映射为查询层逻辑指标（ $O_q = \{\text{同月同比口径}\}$ ），而非在分析层进行自由计算。

规格初始化阶段根据已确定的 T 、 D 、 G 以及可视化规则库 $\mathcal{V}$ 生成初始可视化规格 $\hat{V}$ 和摘要要求 $\hat{S}$ 。此阶段利用表4-3中的默认映射关系确定初始图表类型，并根据指标数量和维度数量调整坐标轴分配与标题内容。

上述映射过程可统一表述为：

$$A^{(0)} = \text{LLM}_{\text{plan}}(x, K, \mathcal{C}), \quad A = \text{BuildPlan}(x, K) \quad (4-6)$$

AP-Schema 的完整生成流程如算法4.1所示。

算法 4.1: AP-Schema 构建算法

Input: 自然语言分析需求 x , 任务类型集合 $\mathcal{T}$, 领域知识 $K = \{B, L, V\}$, 分析算子库 $\mathcal{O}_a$, 可视化规则库 $\mathcal{V}$, 约束规则集 $\mathcal{C}$, 大语言模型 LLM

Output: 分析计划 $A = \langle T, M, D, \hat{F}, G, O_q, O_a, \hat{V}, \hat{S} \rangle$

```

1 初始化:  $A \leftarrow \emptyset$ ;
2  $A^{(0)} \leftarrow \text{LLM}(\text{PromptTemplate}(x, K, \mathcal{C}))$ ; // 按固定槽位输出规划草案
3  $E \leftarrow \text{ParseDraft}(A^{(0)})$ ; // 解析草案中的指标、维度、条件、粒度与展示意图
4  $T \leftarrow \text{IdentifyType}(E, \mathcal{T})$ ; // 识别分析类型
5  $(M, D, \hat{F}, G) \leftarrow \text{ParseSlots}(E, K)$ ; // 归一化指标、维度、条件与粒度
6  $(O_q, O_a) \leftarrow \text{DecomposeOps}(T, M, D, \hat{F}, G, K, \mathcal{O}_a)$ ; // 区分查询层与分析层操作
7  $\hat{V} \leftarrow \text{InitVis}(T, D, G, \mathcal{V})$ ; // 生成初始可视化规格
8  $\hat{S} \leftarrow \text{BuildSummarySpec}(T, M, \hat{V})$ ; // 生成摘要要求
9  $A \leftarrow \langle T, M, D, \hat{F}, G, O_q, O_a, \hat{V}, \hat{S} \rangle$ ;
10 if  $\neg \text{Valid}(A, \mathcal{C})$  then
11    $(M, D, \hat{F}, G) \leftarrow \text{CompleteFields}(x, K, T)$ ; // 基于约束规则触发补全
   // 再次执行重新获取字段信息
12    $(O_q, O_a) \leftarrow \text{DecomposeOps}(T, M, D, \hat{F}, G, K, \mathcal{O}_a)$ 
13    $\hat{V} \leftarrow \text{InitVis}(T, D, G, \mathcal{V})$ 
14    $\hat{S} \leftarrow \text{BuildSummarySpec}(T, M, \hat{V})$ 
15    $A \leftarrow \langle T, M, D, \hat{F}, G, O_q, O_a, \hat{V}, \hat{S} \rangle$ ;
16 end
17 return  $A$ 

```

固定槽位模板要求模型按照 $T \rightarrow M \rightarrow D \rightarrow \hat{F} \rightarrow G \rightarrow O_q/O_a \rightarrow \hat{V}/\hat{S}$ 的顺序输出草案, 从而避免大语言模型在规划阶段直接生成冗长叙述文本。上述流程在返回前需进行基于公式(4-5)的完备性校验。当校验发现规划中存在字段缺失或类型不匹配时, 系统回溯至槽位填充阶段进行二次提取, 并对时间粒度、默认图表类型和摘要要点等字段执行规则化补全, 从而提升规划的鲁棒性。

通过上述四步, 系统可将“分析近两年各区一般公共预算收入的月度趋势, 并给出同比变化”这一自然语言需求映射为表4-4所示的完整 AP-Schema 实例。

最终 AP-Schema 的引入带来三方面收益。其一, 它将分析任务中的隐式约束显式化, 减少系统在后续步骤中遗漏关键分析要求的风险; 其二, 它为数据查询与数据分析模块之间建立了统一接口, 使“取什么数据”和“如何组织分析结果”能够在同一规划框架下协同工作; 其三, 字段约束关系和完备性校验为规划质量提供了可检查的保障机制, 使系统在面对表述不完整或存在歧义的用户输入时仍

表 4-4 自然语言分析需求到 AP-Schema 的映射示例

字段	映射结果
T	trend
M	{一般公共预算收入/SUM, 同比增长率/逻辑指标}
D	{区县, 时间}
$\hat{F}$	{年份 $\in \{2024, 2025\}$ }
G	月度 (month)
O_q	{按区县和月度汇总, 同月同比口径}
O_a	[sort, annotate]
$\hat{V}$	折线图, x 轴 = 时间, y 轴 = 收入金额, 系列 = 区县, 辅助指标 = 同比增长率
$\hat{S}$	趋势摘要: 整体走势、峰值月份、同比最大增幅

能生成结构完整的分析规划。

4.4 基于查询增强的分析任务分解方法

上一节完成了从自然语言需求到 AP-Schema 的结构化规划构建。本节进一步讨论如何将规划中的操作分配给查询层与分析层，并给出两层之间的结果衔接方式。具体而言，本节依次说明查询需求投影与分析需求投影的定义（4.4.1节）、操作归属的判定准则与执行流程（4.4.2节），以及查询层输出的标准结果表示（4.4.3节）。

4.4.1 查询层与分析层的任务划分

据^[80]研究发现以及实践表明，若查询与分析耦合职能划分不明确，则会出现逻辑幻觉重复计算等问题。故本章采用如下划分原则：涉及统计口径、复杂关联或底层数据库计算逻辑的操作，交由第三章查询生成管线完成；本章分析层执行作用于查询结果组织、展示与解释的操作。查询生成在给定用户问题 Q 、数据库模式 S 、领域知识库 K 和动态样例库 F 的条件下完成模式链接、候选生成与候选判别；本章则不直接展开 SQL，而是将与取数相关的约束显式化后交由查询层求解。

为此，本文从 AP-Schema 中分别定义查询需求投影函数与分析需求投影函数：

$$\begin{cases} Q_A = \pi_q(A) = \langle M, D, \hat{F}, G, O_q \rangle \\ P_A = \pi_a(A) = \langle O_a, \hat{V}, \hat{S} \rangle \end{cases} \quad (4-7)$$

其中， Q_A 表示分析规划中与取数相关的结构化约束，描述待查询的指标与聚合要求（ M ）、分组维度（ D ）、过滤条件（ $\hat{F}$ ）、时间粒度（ G ）以及需在查询阶段完成的业务口径操作（ O_q ）； P_A 表示分析层操作链（ O_a ）、可视化规格（ $\hat{V}$ ）和摘要要

求 ($\hat{S}$)。

任务划分的执行流程可概括为四步，如图4-3所示。首先，从 AP-Schema 中抽取指标、维度、条件、粒度和候选操作，形成待判定的取数约束与分析约束；其次，围绕模式依赖性、统计口径依赖性和查询结构复杂性依次判断各操作的归属；再次，将满足查询层条件的部分汇总为 Q_A ，将仅依赖结果组织的部分汇总为 P_A ；最后，由查询层输出标准结果表示 $\mathcal{D}$ ，分析层再据此执行算子调用、可视化映射和摘要生成。由此，任务划分从原则性描述转化为可执行的过程表示。




图 4-3 查询层与分析层任务划分执行流程图

4.4.2 任务分解准则与层级判定

为了在具体操作层面系统地区分 O_q 与 O_a ，本文给出如下判定准则：

$$\phi(o) = \begin{cases} \text{query-layer,} & \text{若 } o \text{ 改变统计口径或依赖底层模式与关系计算} \\ \text{analysis-layer,} & \text{若 } o \text{ 仅对已获取结果集进行重组、展示或解释} \end{cases} \quad (4-8)$$

该准则可进一步落实为四个判定维度：操作是否依赖数据库模式信息、是否改变统计口径、是否需要复杂查询结构支持，以及其直接作用对象是数据库还是结果

集。满足前述任一查询层特征的操作应下沉到查询层，否则保留在分析层。表4-5给出了相应的层级判定矩阵。

表 4-5 任务分解操作的层级判定矩阵

判定维度	查询层特征	分析层特征	判定依据
模式依赖性	需要字段、表关系或类型信息	不再访问底层模式	是否必须依赖 S 完成语义绑定
统计口径依赖性	改变指标定义或聚合口径	不改变既定统计口径	是否需要 L 或预定义业务规则支持
查询结构复杂性	需要关联、子查询或复杂聚合	仅进行轻量结果变换	是否必须通过 SQL 结构求解
操作对象	直接作用于数据库取数过程	直接作用于结果集 $\mathbf{X}$	操作输入是数据库还是查询返回结果

边界情形主要出现在粒度不具体的任务中。例如，“按季度汇总”在已返回月度数据时既可由查询层通过调整分组实现，也可由分析层进一步聚合。针对这类情形，本文采用优先查询层的策略，以减少分析层对原始统计口径的二次加工，并保持结果的一致性与可验证性。

4.4.3 查询结果表示与层间衔接

在完成任务划分后，查询层需要向分析层返回统一的结果表示。本文将 G_q 视为“受约束查询意图进入完整 Text-to-SQL 管线并执行”的上层封装，并将其输出记为：

$$\mathcal{D} = G_q(x, Q_A; S, K, F) = \langle \mathbf{X}, \Gamma, \sigma \rangle \quad (4-9)$$

其中， $\mathbf{X} \in \mathbb{R}^{n \times m}$ 表示以结构化表格形式封装的查询结果， n 为记录数， m 为字段数； $\Gamma = \{(\gamma_j^{\text{name}}, \gamma_j^{\text{type}}, \gamma_j^{\text{unit}}, \gamma_j^{\text{grain}}) \mid j = 1, \dots, m\}$ 表示各字段的名称、数据类型、单位和粒度等元数据； $\sigma \in \{\text{success}, \text{failure}\}$ 表示查询执行状态。

这一结果表示承担三项作用： $\mathbf{X}$ 为分析算子提供直接操作对象， Γ 为可视化映射和展示规则提供字段语义信息， σ 为流程控制提供执行依据。当 $\sigma = \text{failure}$ 时，分析流程应终止并在结果包的 logs 中记录失败原因；当查询执行成功但结果中存在空值、异常粒度或字段说明不足时，系统不再额外设置 partial 状态，而是将相关信息写入 Γ 与结果包的 logs 中，以保持层间接口简洁稳定。

通过 Q_A 与 $\mathcal{D}$ 两个接口，第三章与第四章形成清晰分工：前者负责可靠取数，后者负责规范分析。图4-4进一步展示了操作判定与层间衔接的整体流程。




图 4-4 层间衔接流程图

4.5 基于分析算子的结果生成方法

在查询层返回结果表示 $\mathcal{D}$ 后，系统需要将结构化数据进一步转化为图表、表格和文字洞察。本节首先说明分析算子的设计与编排机制，随后给出结果生成流程与输出组织方式。

4.5.1 分析算子设计与编排

为保持分析层的可控性，本文引入面向结果组织的轻量分析算子库

$$\mathcal{O}_a = \{\text{sort}, \text{topk}, \text{share}, \text{pivot}, \text{annotate}, \text{format}\} \quad (4-10)$$

其中，**sort** 用于排序，**topk** 用于提取头部或尾部结果，**share** 用于补充占比计算，**pivot** 用于重组对比结果，**annotate** 用于标记关键点，**format** 用于统一数值格式、单位与标签表达。算子仅作用于查询结果的组织与展示，不重新定义业务指标。

为保持查询层与分析层的职责边界，**share** 仅在查询层已返回构成项汇总值的前提下计算占比，不重新定义分子和分母；**annotate** 仅从结果表中抽取峰值、最低值、拐点和 Top-k 对象等显式特征；**format** 仅对数值单位、百分比形式和标签文本进行规范化处理。

针对四类典型分析任务，本文设计如下基础算子链：

$$\Psi(T) = \begin{cases} [\text{sort}, \text{annotate}], & T = \text{trend} \\ [\text{pivot}, \text{sort}, \text{annotate}], & T = \text{comparison} \\ [\text{sort}, \text{topk}, \text{format}], & T = \text{ranking} \\ [\text{share}, \text{sort}, \text{annotate}], & T = \text{structural} \end{cases} \quad (4-11)$$

其中，趋势分析强调时间顺序与关键点标注，对比分析强调结果对齐与差异突出，排名分析强调排序和头尾识别，结构分析则在组成部分已完整返回的前提下补充占比与重点类别标注。

设调整后的算子链记为 $\text{chain} = [o_1, o_2, \dots, o_l]$ ，则分析层对查询结果的处理过程可统一表示为：

$$\mathbf{Y} = o_l \circ o_{l-1} \circ \dots \circ o_1(\mathbf{X}, \Gamma) \quad (4-12)$$

其中 $\mathbf{Y}$ 表示算子链执行后的结果表。

在图表选择上，本文采用“初始规格 + 数据后校正”的策略。规划阶段给出初始可视化规格 $\hat{V}$ ，结果返回后再结合类别数、字段类型和时间粒度确定最终图表类型：

$$v^* = \begin{cases} \text{line_chart}, & T = \text{trend} \\ \text{bar_chart}, & T \in \{\text{comparison}, \text{ranking}\} \\ \text{pie_chart}, & T = \text{structural} \text{ 且类别数} \leq 6 \\ \text{stacked_bar_chart}, & T = \text{structural} \text{ 且类别数} > 6 \text{ 或存在时间对比} \end{cases} \quad (4-13)$$

在具体编排时，系统以上游规划给出的分析类型 T 、分析需求投影 $P_A = \langle O_a, \hat{V}, \hat{S} \rangle$ 以及查询结果表示 $\mathcal{D} = \langle \mathbf{X}, \Gamma, \sigma \rangle$ 为输入，先由 $\Psi(T)$ 确定基础算子链，再结合 O_a 中的显式要求以及 Γ 中的字段类型、类别数和粒度信息，对算子顺序和图表规格进行轻量调整，最终得到可执行的算子序列与可视化配置。由此，分析层既保留了类型驱动的稳定性的，又能够对真实数据特征作出必要响应。

4.5.2 结果生成流程与输出组织

在完成算子编排与可视化决策后，系统进入结果生成阶段。该阶段以分析需求投影 $P_A = \langle O_a, \hat{V}, \hat{S} \rangle$ 和查询结果表示 $\mathcal{D} = \langle \mathbf{X}, \Gamma, \sigma \rangle$ 为输入，经过执行状态检查、算子链执行、图表规格修正、摘要生成与结果封装五个步骤，最终输出标准化结果包 R 。算法4.2给出了该流程的详细步骤。

为减少摘要生成过程中的自由发挥，本文将文字洞察生成拆解为“结构化事实抽取”和“摘要组织”两个顺序阶段：

$$\begin{cases} F^* = \text{ExtractFacts}(\mathbf{Y}, \hat{S}), \\ I = \text{Verbalize}(F^*, \hat{S}) \end{cases} \quad (4-14)$$

其中， F^* 表示从结果表中抽取的峰值、增幅、排名和占比等结构化事实集合， I 表示在摘要要求约束下形成的文字洞察。

算法 4.2: 分析结果生成算法

Input: 分析需求投影 $P_A = \langle O_a, \hat{V}, \hat{S} \rangle$ ，查询结果表示 $\mathcal{D} = \langle \mathbf{X}, \Gamma, \sigma \rangle$ ，分析类型 T ，可视化规则库 $\mathcal{V}$

Output: 结果包 $R = \{\text{charts}, \text{tables}, \text{insights}, \text{logs}\}$

```

1 if  $\sigma = \text{failure}$  then
2    $R \leftarrow \{\text{charts} = \emptyset, \text{tables} = \emptyset, \text{insights} = \emptyset, \text{logs}(\sigma, \text{错误原因})\};$ 
3   return  $R$ ; // 查询失败，直接终止
4 end
   // 步骤 1: 选择并执行算子链
5  $\text{chain} \leftarrow \Psi(T);$  // 由分析类型确定基础算子链
6  $\text{chain} \leftarrow \text{Adjust}(\text{chain}, O_a, \Gamma);$  // 结合显式要求与字段元数据调整
7  $\mathbf{Y} \leftarrow \text{Apply}(\text{chain}, \mathbf{X}, \Gamma);$  // 依次执行算子，得到处理后结果
   // 步骤 2: 修正可视化规格
8  $n_{\text{cat}} \leftarrow \text{CountCategories}(\mathbf{Y}, \Gamma);$  // 统计实际类别数
9  $\hat{V}' \leftarrow \text{RefineVis}(\hat{V}, \mathbf{Y}, \Gamma, n_{\text{cat}}, \mathcal{V});$  // 按公式(4-13)校正图表类型
   // 步骤 3: 抽取结构化事实并生成文字洞察
10  $F^* \leftarrow \text{ExtractFacts}(\mathbf{Y}, \hat{S});$  // 抽取峰值、增幅、Top-k、占比等事实
11  $I \leftarrow \text{Verbalize}(F^*, \hat{S});$  // 按摘要要求组织文字洞察
   // 步骤 4: 封装结果包
12  $R \leftarrow \{\text{charts}(\hat{V}', \mathbf{Y}), \text{tables}(\mathbf{Y}), \text{insights}(I), \text{logs}(\sigma, \Gamma)\};$ 
13 return  $R$ 
```

算法4.2有四个关键设计要点。第一，执行状态 σ 的前置检查确保了分析层不会在错误数据上盲目执行算子：当查询失败时直接终止并保留日志，从而避免在无效数据上继续分析。第二，算子链的执行过程采用公式(4-12)所示的确定性组合方式，使系统既遵循类型驱动的基础编排 $\Psi(T)$ ，又能根据 AP-Schema 中用户显式指定的 O_a 和真实数据的字段特征进行微调。第三，文字洞察生成采用公式(4-14)所示的“事实抽取优先”策略，先从结果表中提取峰值、增幅、Top-k 和占比等结构化事实，再在摘要要求 $\hat{S}$ 的约束下组织文本，以降低自由生成导致的结论漂移。第四，可视化规格修正依据公式(4-13)，在真实类别数 n_{cat} 等数据特征的基础上对初

始图表类型进行后校正，避免仅凭自然语言需求过早决定图表类型所带来的偏差。

经过上述流程，系统最终输出的结果包 R 满足公式(4-2)所定义的统一结构，为第五章的系统实现提供了标准化的方法输出接口。

4.6 实验与结果分析

本节旨在验证本章方法的三项核心主张：其一，基于 AP-Schema 的分析规划是否能够提升分析任务完成率与结果稳定性；其二，复用查询生成管线是否能够显著提升数据获取正确性并最终改善分析结果质量；其三，方法中各子模块是否各自具有不可替代的独立贡献。与面向 Text-to-SQL 的大规模基准评测不同，本章实验以中等规模任务集上的端到端验证为主，并通过分类型对比、细粒度模块消融和规划质量评估等多维度实验，体现方法的协同效果与各模块的独立作用。

4.6.1 实验设置与评价指标

实验任务基于第三章构建的同源政务数据库场景展开（见表3-3），仍使用财政预算、公共资源和政务项目等领域的 5 个数据库、33 张数据表作为底层数据来源。在此基础上，本文构建了 56 个自然语言分析任务，其中趋势分析 16 个、对比分析 14 个、排名分析 14 个、结构分析 12 个。每个任务均配备人工核验的参考分析目标，包括目标指标、期望图表类型和关键结论要点。

为保持与第三章的衔接，本章在分析规划阶段采用与第三章相同的 Qwen3-Coder-30B-A3B-Instruct 作为基础模型；数据获取环节直接复用第三章的完整查询生成管线。文字洞察组织阶段仍采用同一基础模型，但其输入被约束为公式(4-14)抽取的结构化事实集合。实验评价采用以下指标。

端到端评价采用四个指标：

流程成功率（Pipeline Success Rate, PSR），表示系统能够完成从分析规划、查询获取到结果生成整个流程并返回有效结果包的比例：

$$PSR = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\text{pipe}_i = 1] \quad (4-15)$$

分析任务完成率（Task Completion Rate, TCR），表示不仅流程执行成功，而且输出图表、表格和摘要在逻辑上满足原始分析意图的比例：

$$TCR = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\text{task}_i = 1] \quad (4-16)$$

结果正确率 (Result Accuracy, RA), 表示在任务完成样本中, 系统输出与人工参考结果一致的比例。对于数值结果, 若相对误差不超过 $\epsilon = 5\%$ 则视为正确:

$$RA = \frac{1}{N_c} \sum_{i=1}^{N_c} \mathbb{I}[\delta(y_i^{pred}, y_i^{ref}) \leq \epsilon] \quad (4-17)$$

其中 N_c 表示任务完成的样本数, $\delta(\cdot)$ 表示相对误差或人工一致性判别函数。

图表恰当性 (Chart Appropriateness, CA), 由 3 名标注者从图表类型选择、坐标映射、标题与标签完整性三个维度进行 1 到 5 分评分, 取平均值:

$$CA = \frac{1}{3N_c} \sum_{i=1}^{N_c} \sum_{j=1}^3 \text{score}_{ij} \quad (4-18)$$

为单独评价 AP-Schema 构建阶段的规划质量, 本文引入以下三个辅助指标。

意图识别准确率 (Intent Accuracy, IA), 表示正确识别分析类型 T 的比例:

$$IA = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[T_i^{pred} = T_i^{ref}] \quad (4-19)$$

槽位填充完备率 (Slot Completeness, SC), 表示 AP-Schema 中各必填字段被正确填充的比例。对于每个任务 i , 设 AP-Schema 共有 $|\mathcal{S}|$ 个必填槽位, 其中正确填充的槽位数为 s_i :

$$SC = \frac{1}{N} \sum_{i=1}^N \frac{s_i}{|\mathcal{S}|} \quad (4-20)$$

约束满足率 (Constraint Satisfaction Rate, CSR), 表示生成的 AP-Schema 通过公式(4-5)完备性校验的比例:

$$CSR = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\text{Valid}(A_i) = \text{true}] \quad (4-21)$$

为验证本章提出的两项核心设计, 本文设置如下三组方法进行比较:

(1) **Direct-Analysis**: 直接将自然语言分析需求端到端映射为分析过程与结果, 不经过显式的 AP-Schema 规划, 也不显式复用第三章查询生成管线;

(2) **Plan+Free-SQL**: 采用 AP-Schema 和结果生成规范, 但在数据获取阶段不调用第三章查询生成管线, 而是在分析流程中自由生成 SQL;

(3) **Ours**: 本文完整方法, 即 “AP-Schema 规划 + 查询增强取数 + 轻量分析算子结果生成”。

4.6.2 结果对比

图4-5给出了三种方法在 56 个政务分析任务上的总体结果。以 56 个任务为分母，Direct-Analysis、Plan+Free-SQL 和本文方法的流程成功任务数分别为 32、42 和 52，任务完成数分别为 22、32 和 48；在完成任样本中，三种方法得到正确分析结果的样本数分别为 16、26 和 46。可以看出，本文方法在流程成功率、任务完成率、结果正确率和图表恰当性四个指标上均明显优于两个对比方法。




图 4-5 不同分析方法的总体实验结果

分析规划显著提升了任务完成稳定性。与 Direct-Analysis 相比，Plan+Free-SQL 在 PSR 上提升了 17.9 个百分点，在 TCR 上提升了 17.8 个百分点。这表明 AP-Schema 能够有效约束系统对指标、维度、时间粒度和展示形式的理解，减少流程中遗漏关键分析要求的情况。

复用查询生成管线是提升整体性能的关键。在已经采用分析规划的前提下，Ours 相较于 Plan+Free-SQL 在 TCR 上进一步提升 28.6 个百分点，在 RA 上提升 14.5 个百分点。这说明若在分析阶段重新自由生成 SQL，仍会重新暴露字段误解、连接错误和过滤条件偏差等问题；而查询生成管线能够提供更可靠的数据输入，使本章方法将注意力集中在分析本身。

图表恰当性受益于轻量算子与规则约束。Ours 在 CA 上达到 4.6 分，说明通过任务类型到图表类型的规则映射，以及结合数据特征的后校正机制，系统生成的图表在类型选择、标题描述和坐标配置上更加规范。

4.6.3 分类型性能对比

为进一步揭示不同分析场景下各方法的表现差异，本文按四种分析类型分别统计三种方法的 TCR 和 RA。表4-6给出了分类型的实验结果。

表 4-6 不同分析类型下各方法的 TCR 与 RA 对比

方法	趋势分析 (16)		对比分析 (14)		排名分析 (14)		结构分析 (12)	
	TCR	RA	TCR	RA	TCR	RA	TCR	RA
Direct-Analysis	31.3	60.0	42.9	83.3	50.0	71.4	33.3	75.0
Plan+Free-SQL	50.0	75.0	64.3	88.9	64.3	77.8	50.0	83.3
Ours	87.5	92.9	85.7	100.0	92.9	92.3	75.0	100.0

趋势分析对分析规划的依赖最为明显。趋势分析要求系统正确识别时间维度、统计粒度（月度/季度）和同比口径等多重约束。Direct-Analysis 在此类型上的 TCR 仅为 31.3%，说明在缺乏显式规划时，系统经常遗漏时间粒度或同比要求。引入 AP-Schema 后（Plan+Free-SQL），TCR 提升至 50.0%；而本文完整方法进一步将 TCR 提升至 87.5%，表明查询增强机制能够有效保障逻辑指标的正确计算。

对比分析与结构分析受益于查询增强取数最为显著。在这两类任务中，本文方法的 RA 均达到 100.0%，而 Plan+Free-SQL 的 RA 分别为 88.9% 和 83.3%。对比分析要求系统在同一口径下获取多个对象的数据，结构分析需要获取完整的组成项汇总值，二者对查询结果的完整性和一致性有较高要求。自由生成 SQL 时容易出现过滤条件偏差或聚合范围不一致，导致数据缺失或口径错误。

排名分析的 TCR 最高。本文方法在排名分析上的 TCR 达到 92.9%，在四类任务中最高。这主要因为排名分析的结构相对规整（排序 + Top-k），AP-Schema 的约束和算子链 $\Psi(\text{ranking}) = [\text{sort}, \text{topk}, \text{format}]$ 能够直接映射为稳定的执行流程。

结构分析的 TCR 相对偏低，但 RA 最高。结构分析的 TCR 在四类任务中最低，主要原因是部分结构分析任务的分类维度较复杂，规划阶段有时将分类维度误判为对比维度，导致生成的 AP-Schema 类型不匹配。而一旦任务完成其 RA 达到 100.0%，说明在规划正确的前提下，查询增强机制和占比算子能够可靠地产出正确结果。

4.6.4 模块消融实验

总体结果对比已验证了分析规划与查询增强两大核心设计的整体效果。为更精确地量化各子模块的独立贡献，本文在完整方法的基础上分别关闭五个关键子模块，观察端到端指标的变化。与宏观方案对比不同，本节所有消融配置均保留完整的方法框架（AP-Schema + 查询增强 + 结果生成），仅逐一移除特定子模块，以隔离其独立作用。表4-7给出了消融实验结果。

w/o Completeness Validation（去除完备性校验）。保留 AP-Schema 的结构化表示，但跳过公式(4-5)的约束校验与字段补全机制。去除后，TCR 和 PSR 性能下

表 4-7 模块消融实验结果

模型方法	PSR/%	TCR/%	RA/%	CA/分
w/o Completeness Validation	87.5	75.0	92.9	4.4
w/o Task Decomposition	89.3	78.6	86.4	4.1
w/o Operator Chain $\Psi(T)$	91.1	80.4	93.3	3.8
w/o Chart Post-correction	92.9	83.9	95.8	3.9
w/o Fact Extraction	92.9	82.1	93.5	4.0
Full Model	92.9	85.7	95.8	4.6

降。分析发现，失败案例主要集中在趋势分析和结构分析中：前者因缺少时间维度校验导致 G 字段缺失，后者因分类维度未通过约束检查而遗漏关键分组条件。这表明完备性校验是 AP-Schema 从“结构化表示”走向“可靠规划”的关键保障。

w/o Task Decomposition（去除查询/分析层分解）。保留 AP-Schema 和查询增强取数，但不再将操作显式区分为 O_q 和 O_a ，而是将所有操作统一交由大语言模型自行决定分配。去除后，RA 降幅达 9.4 个百分点。错误显示，系统在缺乏显式分层时容易将本应由查询层处理的统计口径操作错误地放入分析层自由计算，导致数值偏差。这说明公式(4-8)所定义的层级判定准则是保证数据正确性的重要机制。

w/o Operator Chain $\Psi(T)$ （去除类型驱动算子链）。保留查询增强取数，但分析层不使用公式(4-11)定义的预设算子链，改由大语言模型自由组织结果展示。去除后，CA 降幅最为明显；TCR 也下降至 80.4%。自由组织模式下，系统在排名分析中经常遗漏 Top-k 截取，在结构分析中未执行占比计算，导致结果不完整。这表明类型驱动的算子链为分析层提供了稳定的执行骨架，避免结构性遗漏。

w/o Chart Post-correction（去除图表后校正）。保留所有其他模块，但图表类型始终使用规划阶段初始化的 $\hat{V}$ ，不再根据实际类别数等数据特征进行校正。去除后，PSR 和 RA 均未受影响，但 CA 从 4.6 分下降至 3.9 分。典型错误包括：当结构分析返回的类别数超过 6 个时仍使用饼图（可读性差），以及当对比维度仅有两个对象时使用多系列柱状图而非更清晰的分组柱状图。这说明公式(4-13)的后校正机制虽不影响数据正确性，但对图表展示的规范性具有显著提升。

w/o Fact Extraction（去除结构化事实抽取）。保留所有其他模块，但文字洞察不经过公式(4-14)的两阶段管线，而由大语言模型直接从结果表生成摘要文本。去除后，TCR 下降至 82.1%，CA 从 4.6 分下降至 4.0 分，RA 也略降至 93.5%。自由摘要模式下，系统偶尔在洞察中引入结果表中不存在的数值（如编造排名位次或增幅百分比），导致标注者判定为任务未完成或结果不正确。这表明“先抽取事实、再组织文本”的约束策略能有效抑制大语言模型在摘要生成中的结论漂移。

4.6.5 AP-Schema 规划质量评估

上述实验从端到端角度评价了整体方法效果，但无法直接反映 AP-Schema 构建过程本身的质量。为此，本文单独评估规划阶段的输出，以验证固定槽位模板与完备性校验机制对规划质量的提升作用。

实验对比两种配置：（1）LLM 直接生成，即不使用固定槽位模板，也不执行约束校验，由大语言模型以自由文本形式输出分析规划；（2）本文方法，即采用固定槽位模板引导草案生成，并通过公式(4-5)进行约束校验与字段补全。评估基于 56 个分析任务，每个任务的参考 AP-Schema 由人工标注确定。表4-8给出了两种配置在意图识别准确率（IA）、槽位填充完备率（SC）和约束满足率（CSR）三个指标上的结果。

表 4-8 AP-Schema 规划质量评估结果

配置	IA/%	SC/%	CSR/%
LLM 直接生成	78.6	67.3	53.6
本文方法	94.6	91.8	91.1

固定槽位模板显著提升了意图识别准确率。LLM 直接生成配置的 IA 为 78.6%，错误主要集中在趋势分析与对比分析的混淆（如将“各区收入变化对比”误判为对比分析而非趋势分析），以及排名分析与结构分析的边界模糊。本文方法通过固定槽位模板强制模型先输出 T 字段再填充后续字段，使 IA 提升至 94.6%。

槽位填充完备率的提升体现了结构化模板的约束作用。LLM 直接生成时，SC 仅为 67.3%，常见遗漏包括分析粒度 G 、查询层操作 O_q 和摘要要求 $\hat{S}$ 等非显式字段。本文方法通过固定槽位顺序和领域知识库辅助填充，将 SC 提升至 91.8%。

约束校验机制是保障规划可执行性的核心。LLM 直接生成的 CSR 仅为 53.6%，即近半数规划不满足表4-3定义的类型约束（如趋势分析缺少时间维度、结构分析缺少分类维度）。本文方法通过完备性校验与二次补全将 CSR 提升至 91.1%，使绝大多数规划在进入查询投影阶段前即满足结构完备性要求。

4.7 本章小结

本章针对政务智能问数中“查到数据后如何规范分析”的问题，提出了基于分析规划与查询增强的政务数据分析方法。该方法引入 AP-Schema 将开放式分析需求转化为结构化规划，通过查询增强的任务分解机制复用第三章的可靠取数能力，并借助轻量分析算子库与可视化规则实现规范化的结果生成。实验表明，本文方法在任务完成率、结果正确率和图表恰当性上均显著优于对比方法；分类型对比、

细粒度模块消融和规划质量评估三组实验进一步验证了各子模块的独立贡献与设计必要性。由此，第三章解决可靠取数，本章解决规范分析，二者共同为第五章的系统实现提供完整的方法基础。

第 5 章 政务智能问数系统设计与实现

5.1 引言

在第三章和第四章查询与分析方法构建的基础上，本文实现了一个面向政务场景的智能问数系统，并将查询生成方法与分析生成方法整合到统一后端服务之中。该系统能够完成从自然语言输入、可靠取数、结构化分析到结果组织与追溯的完整流程。

系统核心能力主要包括：**（1）自然语言问数**。支持用户以自然语言提交查询类或分析类请求，并由应用层完成统一接入与任务分发；**（2）可靠查询生成**。复用第三章的 LA-Schema 增强、异构候选生成、查询修复与候选判别能力，输出高可信度 SQL 及其结果表；**（3）自动化分析生成**。复用第四章的 AP-Schema 构建、查询增强取数和分析算子编排能力，生成图表、表格与文字洞察；**（4）结果留痕与追溯**。完整保存任务状态、中间产物、执行日志和结果文件，以支持后续复核、追问与问题定位。

围绕这一目标，本章从系统总体架构、应用层与智能服务层实现、系统数据层存储以及系统功能实现与效果展示四个方面展开。

5.2 系统总体架构

为满足查询、分析、会话管理和结果追溯等工程需求，本文实现的政务智能问数系统采用由表示层、应用层、智能服务层和数据层组成的四层架构，如图5-1所示。该分层方式使交互界面、HTTP 接入、智能编排与底层存储相互解耦，利于保持模块边界清晰。

表示层直接面向用户，负责承接自然语言输入、呈现 SQL 与查询结果、展示分析图表与文字洞察，并提供历史会话与结果追溯入口。表示层通过统一接口调用应用层服务，并将后端返回的结构化结果可视化呈现。

应用层采用基于 Python 的 Web 服务栈实现，以 FastAPI 作为统一 HTTP 入口，配合 Pydantic 完成请求对象建模、参数校验和响应序列化。本层同时承担任务创建、状态维护、统一异常处理和 SSE（Server-Sent Events）流式输出等职责，使查询请求和分析请求都以标准化接口进入系统。

智能服务层是系统的核心执行层。本研究采用 LangGraph 的 StateGraph 实现服务级编排，并将查询能力与分析能力分别封装为查询子图和分析子图。其

中，查询服务封装第三章提出的完整查询链路，对外返回 `QueryResponse`；分析服务封装第四章提出的分析规划、查询增强取数和结果生成链路，对外返回 `AnalysisResultResponse`，其结果主体为 `ResultPackage`。对于分析请求，系统先在分析子图中生成 `AP-Schema`，再投影得到查询约束，并由查询调用节点复用查询子图完成取数；查询结果返回后，再进入分析算子、图表构建和洞察生成节点完成结果组织。在这一层中，本地大模型不直接暴露给前端，而是由 HTTP 调用器以受约束方式供各节点复用。

数据层为上层服务提供稳定的数据与知识支撑。政务业务库保存财政、项目、公共资源等原始业务数据；PostgreSQL 保存系统元数据、领域知识库与会话状态；Milvus 承载值检索与样例检索向量索引；Redis 保存热点缓存、任务热状态和流式事件通道；图表与导出文件则以文件路径方式登记到结果产物表中。其中，应用层和智能服务层通过 SQLAlchemy 统一管理元数据库等核心对象。




图 5-1 系统总体分层架构图

5.3 应用层与智能服务层实现

5.3.1 应用层接口设计

应用层采用 FastAPI 构建统一 HTTP 服务入口，以 Pydantic 完成请求校验与响应序列化，并围绕查询和分析两类核心业务对外提供标准化接口。

在接口组织上，系统采用同步查询、异步分析的调用策略。**同步查询接口**在请求上下文中直接执行查询子图并返回 `QueryResponse`，同时支持 SSE 流式模

式，将各节点进度实时推送给前端；异步分析接口采用“先建任务、后执行”的模式，创建任务后由后台执行器触发分析子图，任务完成后再通过结果接口返回 `AnalysisResultResponse`，其中核心结果对象为 `ResultPackage`。此外，系统提供统一的任务状态查询、结果获取和事件订阅接口，使查询与分析的结果回传共享同一交互范式。

在查询与分析的链路衔接上，分析请求并不会绕过查询服务直接生成图表或结论，而是先由分析规划节点生成 `AP-Schema`，再由查询投影节点提取指标、维度、筛选条件和统计粒度等查询约束，并由查询调用节点复用查询子图。查询子图复用第三章中的 `LA-Schema` 增强、异构候选生成、查询修复与候选判别流程，返回结果表及执行状态；分析子图再基于该结果完成分析算子执行、图表构建、文字洞察和结果封装，从而生成 `ResultPackage`。

在异常处理上，应用层通过全局异常拦截器将参数错误、权限异常、任务状态异常等规范化为统一响应结构，并为每个请求生成唯一追踪标识，与任务标识一同贯穿服务层和日志系统，为后续错误定位与结果回放提供依据。




图 5-2 同步查询、异步分析与流式回传时序图

5.3.2 任务状态管理与异常回传

为直观说明同步查询、异步分析与流式回传三种实现方式之间的关系，图5-2给出了应用层和智能服务层的时序交互。

系统在任务层维护由 PENDING、RUNNING、SUCCESS 和 FAILED 组成的统一状态机。查询同步接口在用户视角上即时返回，但内部仍经历完整的“建任务—执行—写日志—回传结果”状态流转；分析异步接口则明确依次经历各状态阶段。所有状态转移均同步写入持久层并通过 SSE 事件推送给前端。

异常处理与结果回传机制如图5-3所示。




图 5-3 异常处理与结果回传实现图

在异常分类上，应用层异常由全局异常处理器拦截，涵盖参数校验失败、权限不足和非法状态访问等；服务层异常由子图节点内部捕获，涵盖 SQL 执行错误、分析算子异常和大模型调用超时等。对于可恢复错误，系统在节点内执行有限轮次的自动修复并记录重试日志；对于不可恢复错误，系统将任务标记为失败并向

前端推送失败事件。系统最终通过结果产物表和结构化日志保存关键中间对象和最终结果，使前端能够基于任务标识完成结果回放和链路追踪。

5.4 系统数据层存储

为使上述应用层接口和智能服务层编排稳定运行，还需要有针对性的存储机制来承接数据源接入、元数据抽取、任务状态保存和结果产物管理。故本节从业务数据源接入与元数据抽取、系统元数据库实现以及结果与缓存管理三个方面说明数据存储实现。

5.4.1 业务数据源接入与元数据抽取

在工程实现上，系统通过 JDBC/ODBC 等标准数据库连接方式建立到外部数据源的连接，并在 `data_source` 表中维护数据源标识、数据库类型、连接配置和同步策略等元信息。应用层中的数据源管理接口负责维护这些配置，而后台元数据同步任务则定期触发表结构扫描和索引更新。

此外系统还必须对外部数据源执行结构化元数据抽取。如图5-4所示，元数据抽取流程包含表结构抽取、字段属性抽取、主外键关系抽取以及样例值和枚举值抽取四个环节。




图 5-4 业务数据源接入与元数据抽取实现图

其中，**表结构抽取**负责获得库、表和字段的基础信息，包括表名、表注释、字段名、数据类型、主键标识和字段注释等；**关系抽取**负责显式发现数据库中的主外键关系，并将其转化为统一的 `schema_relation` 记录，以支撑后续多表 JOIN 推理；**样例值抽取**面向行政区划、项目状态、支出类别等典型枚举型或文本型字段，抽取少量样例值或完整值域，用于值匹配与语义提示；**向量索引构建**则将关键字段值与动态样例检索所需内容编码后写入 Milvus，为第三章中的值检索与样例检索提供在线支持。

经过上述过程后，系统在 PostgreSQL 中形成 data_source、schema_table、schema_column 和 schema_relation 等标准元数据表，在 Milvus 中形成面向值检索与样例检索的向量索引。在线查询时，schema_retriever 从 schema_* 表中读取与当前问题相关的结构元数据，knowledge_retriever 从领域知识库 $K = \{B, L, V\}$ 中读取术语映射、逻辑公式和值域约束，example_retriever 则基于动态样例库 F 及其向量索引完成相似样例召回。三类信息在查询子图中共同用于构建 LA-Schema。因此，元数据抽取模块实际上承担了从“外部数据库原始结构”到“可被查询方法使用的统一知识表示”之间的桥梁作用。

5.4.2 系统元数据库实现

系统自身维护一个独立的元数据库来持久化保存会话、任务、产物和日志等状态对象。应用层和智能服务层通过 SQLAlchemy 统一管理 query_task、analysis_task、execution_log 和 result_artifact 等核心表，本文实现了如表5-1所示的系统核心数据表，并在图5-5中给出了它们之间的主要关联关系。




图 5-5 系统元数据库 ER 图

从结构关系看，源数据侧由 data_source、schema_table、schema_column 和 schema_relation 共同构成统一结构描述；会话侧由 session_context、query_task 和 analysis_task 共同构成交互过程的状态管理；产物侧则由 result_artifact 和 execution_log 承接任务级结果沉淀与运行留痕。由于查询任务和分析任务都可能生成多个结果文件和多条日志记录，因此系统将产物和日志分别实现为独立从表，并通过 task_type 与 task_id 完成关联。

表 5-1 系统元数据库核心表结构

表名	关键字段	主要说明
data_source	source_id source_name db_type	保存外部政务数据源配置和同步信息，是元数据抽取的起点。
schema_table	table_id source_id table_name	保存库级与表级结构信息，供模式链接和多库定位使用。
schema_column	column_id table_id column_name sample_values	保存字段类型、注释和样例值，是 LA-Schema 构建的直接输入。
schema_relation	relation_id source_table_id target_table_id	保存主外键关系或显式 JOIN 关系，为复杂查询生成提供连接先验。
session_context	session_id history_summary current_query	保存会话级上下文摘要、最近任务产物和用户反馈，是多轮交互的核心状态表。
query_task	task_id session_id nl_query final_sql	保存查询任务主记录，记录原始问题、最终 SQL 和执行状态。
analysis_task	task_id session_id nl_query ap_schema	保存分析任务主记录，其中 ap_schema 采用 JSON 对象存储。
result_artifact	artifact_id task_type task_id content	统一登记查询结果表、图表文件、文本洞察和导出文件等产物。
execution_log	log_id task_type task_id agent_name	按步骤记录执行状态、异常信息和关键信息快照，是问题定位与结果追溯的基础。

5.4.3 结果、日志与缓存管理

在持久化存储策略上，系统根据对象类型将其分别落到最合适的组件中。具体而言，PostgreSQL 负责保存系统元数据、任务主记录和领域知识库；Milvus 负责保存字段值向量和样例向量索引；Redis 负责热点缓存、任务热状态以及 SSE 事件通道；图表文件、导出文件和大体积结果文件则采用文件路径方式登记到 result_artifact 中。

在结果管理方面，系统将查询结果表、图表文件、洞察文本、导出文件统一抽象为结果产物。对于查询任务，重点保存 final_sql、结果表摘要和原始结果文件；对

于分析任务，重点保存 `ap_schema`、图表描述、分析表格和 `insights` 文本。若用户在已有查询结果基础上继续发起分析任务，系统仅在当前分析任务与已有查询结果在指标、维度、筛选条件和统计粒度上兼容时优先复用相应 `result_artifact`；若不兼容，则由分析服务重新触发查询子图完成取数。

在日志管理方面，`execution_log` 采用结构化写法，至少记录 `task_id`、节点名称、执行步骤、状态、日志内容和时间戳。与仅保存文本日志不同，结构化日志可以支持按任务、代理或节点维度检索，能够快速定位错误是发生在模式链接、候选判别、分析算子、图表生成还是结果封装环节。

在缓存管理方面，系统主要缓存两类内容。第一类是变化频率较低但访问频繁的元数据与知识对象，如表结构摘要、字段样例值和部分领域知识片段；第二类是高频相同请求对应的查询结果摘要、分析结果引用以及流式事件缓冲。由于政务问数场景并不追求毫秒级实时更新，因此在保证缓存失效策略合理的前提下，引入 Redis 可以有效降低重复请求对数据库和大模型服务的压力。

5.5 系统功能实现与效果展示




图 5-6 系统对话主页面


基于上述架构、应用层接口和智能服务层实现，本文系统为此展示对应自然语言输入、SQL 与结果查看、分析结果展示等内容。考虑到政务业务数据与真实

界面内容涉及隐私和篇幅限制，效果展示数据为 Mock 非真实值。

以下页面概括展示已实现系统的核心界面结构。

自然语言输入对话主页面。图5-6是系统的主要交互入口，底部提供自然语言输入框，左侧提供历史会话列表，主区域展示用户与系统的交互内容。右侧包含相关细节的展示，包含有分析规划、执行轨迹、数据与知识信息等。用户可以直接输入查询类或分析类需求，也可以在已有会话中继续追问。

分析图表与文字洞察。如图5-7a。当任务属于分析类请求，或用户在查询结果基础上发起分析时，系统在该页面展示图表、分析表格和文字洞察。在输出过程中会展示分析规划（计划）和执行轨迹。同时支持用户针对已有的分析结果进行追问，系统会根据追问内容生成新的分析规划和执行轨迹。如图5-7b。



(a) 分析需求问答展示

(b) 分析需求追问

图 5-7 分析图表与文字洞察

SQL 与查询结果展示。如图5-8。当任务被判定为查询类请求或涉及到查询并成功执行后，系统在该页面展示查询计划与最终 SQL 语句和结果表（明细表）。结果表区域则为后续人工复核、导出或发起一键分析提供基础。

数据结果追溯。如图5-9。每次查询或者分析任务，都要在主页面的右侧展示




图 5-8 SQL 与查询结果展示

使用的数据与知识，方便进行追溯分析。



(a) 执行轨迹

(b) 使用数据与知识

图 5-9 问答执行轨迹与数据追溯

系统功能页面并不是独立于方法之外的界面拼装，而是把第三章的查询能力、第四章的分析能力以及第五章的应用层接口、智能服务层编排和结果追溯机制，统一组织到一个已经实现的政务智能问数系统中。用户在界面层面看到的是一次自然的问数与分析过程，而在系统内部则对应着 FastAPI 接口接入、LangGraph 子图编排、Redis 事件推送和结构化状态流转的工程实现。

5.6 本章小结

本章从工程实现角度说明了政务智能问数系统的落地方式。系统采用表示层、应用层、智能服务层和数据层四层架构，由应用层统一接入自然语言请求，并在智能服务层编排查询子图与分析子图，完成同步查询、异步分析以及任务状态与结果的统一管理。

第三章提供可靠取数能力，第四章提供规范分析能力，第五章则将二者组织为一个可交互、可追溯的统一系统：分析请求先形成 **AP-Schema** 并投影查询约束，再复用查询子图完成取数，最终生成图表、表格和文字洞察。由此，全文形成了从方法设计到系统实现的完整闭环。

结论与展望

致 谢

“诤实扬华，自强不息。”岁月不居，时节如流。在交大度过的七载春秋，不仅是我求学生涯中最宝贵的时光，更是我人生观与价值观成型的关键阶段。回首往昔，心中满是感激与敬畏。

首先，深切感谢我的恩师郑宇教授。郑老师不仅在科研上给予我启发式的指引，更在处世态度与人生认知上教会了我深刻的方法论。郑老师治学严谨、精益求精的学者风范，以及对前沿技术的敏锐洞察，令我受益终生。感念郑老师在我迷茫时的悉心点拨，这份师恩，我将永远铭记，并在未来的职业道路上以此自勉。

感谢何华均师兄和麻志鹏师兄。你们严谨认真的科研精神和青云直上的实践态度，潜移默化地影响着我。感谢你们在我遇到瓶颈时提供的无私指导，让我在科研的道路上走得更加踏实。

研途漫漫，感谢在京东科技度过的充实时光。这里承载了我研究生生涯的大半记忆。特别感谢韩博洋和孟垂实两位老师的悉心指导与包容，让我在工业界实战中飞速成长。感谢张晓龙、王璐璐、赵大燕、黎世骄、陈海乐等师兄师姐的并肩作战与温情陪伴，你们的出现，让我的生活绚烂多彩。同时，也感谢师弟吴晨宇、虞杰杰、巴聪聪等在工作与科研中的默契协作。

感恩在清华大学智能产业研究院以及字节跳动的宝贵经历。让我深刻体会到了“敢为极致、勇攀高峰”的精神。这些经历磨炼了我的韧性，也拓宽了我看世界的视野。

特别致谢陪伴我走过七载春秋的同门挚友：徐梓航、崔智源、柴江波、王一凡、温海泉。我们的情谊起笔于那个疫前未染尘埃的仲秋，在拔尖班的初见中定格；又在求职毕业、尘埃落定后的盛夏，于奔赴北上深杭的万水千山间，写下这一阶段的终章。科学研究表明，人体细胞每七年就会完成一次整体的更新；何其有幸，在这场漫长的更迭中，是你们陪我见证了从旧我向新我的重塑与蜕变。其深厚羁绊，不仅是学术路上的并肩，更是我求学岁月里最温情、也最坚韧的收获。

最后，感谢一路上相知相遇的每一个人。感谢那个曾在多地奔波、却从未放弃的自己。感谢自己在无数个深夜的坚守，以及面对未知挑战时的勇气。

愿此去繁花似锦，归来仍是少年。

参考文献

- [1] 国务院. 国务院关于加强数字政府建设的指导意见, 2022, 国发〔2022〕14号.
- [2] 中共中央, 国务院. 数字中国建设整体布局规划, 2023.
- [3] 国家发展改革委, 国家数据局, 工业和信息化部. 国家发展改革委国家数据局工业和信息化部关于印发《国家数据基础设施建设指引》的通知, 2025, 发改数据〔2024〕1853号.
- [4] 孟天广, 张小劲. 数字政府发展的国际比较与中国路径 [J]. 公共管理学报, 2021, 18(1): 121–133.
- [5] 张聪丛, 张楠, 孟庆国. 政务数据治理研究综述: 概念框架与发展趋势 [J]. 电子政务, 2024, (3): 2–16.
- [6] 王璐璐, 何华均, 潘哲逸, 等. 面向政府大规模协同任务的时空数据管理和分析研究 [C]. 第40届CCF中国数据库学术会议 (NDBC 2023), 贵州, 2023.
- [7] Wang L, He H, Pan Z, et al. An efficient system for large-scale collaborative tasks in government [J]. Human-Centric Intelligent Systems, 2024, 4: 406–416.
- [8] OpenAI. GPT-4 technical report [J]. arXiv preprint arXiv:230308774, 2023.
- [9] Bai J, Bai S, Chu Y, et al. Qwen technical report [J]. arXiv preprint arXiv:230916609, 2024.
- [10] DeepSeek-AI. DeepSeek-V3 technical report [J]. arXiv preprint arXiv:241219437, 2024.
- [11] Zhao W X, Zhou K, Li J, et al. A survey of large language models [J]. arXiv preprint arXiv:230318223, 2023.
- [12] Liu J, Lin J, Huang S, et al. A survey of text-to-SQL: advances, challenges, and future directions [J]. The VLDB Journal, 2025, 34(1): 1–35.
- [13] Hong S, Lin Y, Liu B, et al. Data interpreter: an LLM agent for data science [J]. arXiv preprint arXiv:240218679, 2024.
- [14] Gu C, Li X, others. Analysts: are large language models viable data analysts? [J]. arXiv preprint arXiv:240217032, 2024.
- [15] 王昀, 胡珉, 塔娜, 等. 大语言模型及其在政务领域的应用 [J]. 清华大学学报 (自然科学版), 2024, 64(4): 649–658.
- [16] 沈宇, 黄卫东, 叶文武. 基于大模型 nl2sql 的交通系统运行智能问数助手技术研究 [J]. 信息通信技术, 2025, 19(3): 29–36.
- [17] 兰洪浩, 高长伟, 房秉毅, 等. 政务大模型在民生服务领域的创新应用与价值创造 [J]. 信息通信技术, 2025, 19(3): 9–13.

- [18] Yu T, Zhang R, Yang K, et al. Spider: a large-scale human-labeled dataset for complex and cross-database semantic parsing and text-to-SQL task [C]. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, 2018: 3911–3921.
- [19] Liu J, Li D, Chen B, et al. Can LLM already serve as a database interface? a big bench for large-scale database grounded text-to-SQLs [J]. Advances in neural information processing systems, 2025, 37: 61588–61617.
- [20] 王昊奋, 陈卓, 丁恒, 等. 大语言模型赋能的自然语言查询数据库技术综述 [J]. 软件学报, 2024, 35(8): 3790–3812.
- [21] Ma P, Ding R, Wang S, et al. InsightPilot: an LLM-empowered automated data exploration system [C]. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 2023: 346–360.
- [22] Zhong V, Xiong C, Socher R. Seq2SQL: generating structured queries from natural language using reinforcement learning [C]. arXiv preprint arXiv:1709.00103, 2017.
- [23] Yu T, Yasunaga M, Yang K, et al. SyntaxSQLNet: syntax tree networks for complex and cross-domain text-to-SQL task [C]. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, 2018: 1653–1663.
- [24] Wang B, Shin R, Liu X, et al. RAT-SQL: relation-aware schema encoding and linking for text-to-SQL parsers [C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020: 7567–7578.
- [25] Lin X V, Socher R, Xiong C. Bridging textual and tabular data for cross-domain text-to-SQL semantic parsing [C]. Findings of the Association for Computational Linguistics: EMNLP 2020, 2020: 4870–4888.
- [26] Scholak T, Schucher N, Bahdanau D. PICARD: parsing incrementally for constrained autoregressive decoding from language models [C]. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, 2021: 9895–9901.
- [27] Li H, Zhang J, Li C, et al. RESDSQL: decoupling schema linking and skeleton parsing for text-to-SQL [C]. Proceedings of the AAAI Conference on Artificial Intelligence, 37(11), 2023: 13067–13075.
- [28] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners [C]. Advances in neural information processing systems, 33, 2020: 1877–1901.
- [29] Gao D, Wang H, Li Y, et al. Text-to-SQL empowered by large language models: a benchmark evaluation [C]. Proceedings of the VLDB Endowment, 17(5), 2024: 1132–1145.

- [30] Pourreza M, Rafiei D. DIN-SQL: decomposed in-context learning of text-to-SQL with self-correction [J]. *Advances in neural information processing systems*, 2024, 36: 36339–36348.
- [31] Pourreza M, Rafiei D. CHASE-SQL: multi-path reasoning and preference optimized candidate selection in text-to-SQL [J]. *arXiv preprint arXiv:241001943*, 2024.
- [32] Gao Y, Wang Y, Li Y, et al. XiYan-SQL: a multi-generator ensemble framework for text-to-SQL [J]. *arXiv preprint arXiv:241108599*, 2024.
- [33] Xie X, Zhang G, Wang F, et al. OpenSearch-SQL: enhancing text-to-SQL with dynamic few-shot and consistency alignment [J]. *arXiv preprint arXiv:250214913*, 2025.
- [34] Li B, Mou Y, Li J, et al. Alpha-SQL: zero-shot text-to-SQL via monte carlo tree search [J]. *arXiv preprint arXiv:250217600*, 2025.
- [35] Li J, Hui B, others. OmniSQL: synthesizing high-quality text-to-SQL data at scale [J]. *arXiv preprint arXiv:250302164*, 2025.
- [36] Talaei S, Pourreza M, Chang Y C, et al. CHEMA: contextual harnessing for efficient SQL synthesis [J]. *arXiv preprint arXiv:240516755*, 2024.
- [37] Li H, Zhang J, Han H, et al. CodeS: towards building open-source language models for text-to-SQL [J]. *Proceedings of the ACM on Management of Data*, 2024, 2(3): 1–28.
- [38] Chen M, Tworek J, Jun H, et al. Evaluating large language models trained on code [J]. *arXiv preprint arXiv:210703374*, 2021.
- [39] Rozière B, Gehring J, Gloeckle F, et al. Code Llama: open foundation models for code [J]. *arXiv preprint arXiv:230812950*, 2023.
- [40] Li R, Allal L B, Zi Y, et al. StarCoder: may the source be with you! [J]. *arXiv preprint arXiv:230506161*, 2023.
- [41] Luo Z, Xu C, Zhao P, et al. WizardCoder: empowering code large language models with Evol-Instruct [J]. *arXiv preprint arXiv:230608568*, 2023.
- [42] Dibia V. LIDA: a tool for automatic generation of grammar-agnostic visualizations and infographics using large language models [J]. *arXiv preprint arXiv:230302927*, 2023.
- [43] Maddigan P, Susnjak T. Chat2VIS: generating data visualisations via natural language using ChatGPT, Codex and GPT-4 [C]. *IEEE Access*, 11, IEEE, 2023: 45181–45193.
- [44] Qin B, Chen S, Zhu Y, et al. TaskWeaver: a code-first agent framework [C]. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics: System Demonstrations*, 2024: 262–273.

- [45] Zhang W, Dang Y, Liu B, et al. Data-Copilot: bridging billions of data and humans with autonomous workflow [J]. arXiv preprint arXiv:230607209, 2024.
- [46] Huang A, Zha D, Shen Y, et al. TableGPT2: a large multimodal model with tabular data integration [J]. arXiv preprint arXiv:241102059, 2024.
- [47] Tian Y, Cui W, Deng D, et al. ChartGPT: leveraging LLMs to generate charts from abstract natural language [J]. IEEE Transactions on Visualization and Computer Graphics, 2024, 30(1): 1–11.
- [48] 孟庆国, 鞠京芮. 人工智能支撑的平台型政府: 技术框架与实践路径 [J]. 电子政务, 2021, (9).
- [49] 赵大燕, 何华均, 李宇平, 等. 面向政务协同的访问控制模型 [J]. 计算机应用, 2025, 45(1).
- [50] 王薇, 庞晓博. 政务大模型应用策略研究 [J]. 信息通信技术与政策, 2025, 51(11): 74–80.
- [51] 吴重庆, 杨思哲, 宁庭勇, 等. 上海政务垂类大模型应用探索 [J]. 信息通信技术与政策, 2025, 51(8): 78–83.
- [52] 朱炫鹏, 姚海东, 刘隽, 等. 大语言模型算法演进综述 [J]. 中兴通讯技术, 2024, 30(2): 9–20.
- [53] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [C]. Advances in neural information processing systems, 30, 2017: 1–11.
- [54] Radford A, Narasimhan K, Salimans T, et al. Improving language understanding by generative pre-training [J]. OpenAI Technical Report, 2018.
- [55] Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners [J]. OpenAI Technical Report, 2019.
- [56] Devlin J, Chang M W, Lee K, et al. BERT: pre-training of deep bidirectional transformers for language understanding [C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2019: 4171–4186.
- [57] Raffel C, Shazeer N, Roberts A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer [J]. Journal of Machine Learning Research, 2020, 21(140): 1–67.
- [58] Wei J, Bosma M, Zhao V Y, et al. Finetuned language models are zero-shot learners [C]. International Conference on Learning Representations, 2022.
- [59] Chung H W, Hou L, Longpre S, et al. Scaling instruction-finetuned language models [J]. Journal of Machine Learning Research, 2024, 25(70): 1–53.
- [60] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback [J]. Advances in neural information processing systems, 2022, 35: 27730–27744.

- [61] Dong Q, Li L, Dai D, et al. A survey on in-context learning [J]. arXiv preprint arXiv:230100234, 2023.
- [62] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models [C]. Advances in neural information processing systems, 35, 2022: 24824–24837.
- [63] Kojima T, Gu S S, Reid M, et al. Large language models are zero-shot reasoners [C]. Advances in neural information processing systems, 35, 2022: 22199–22213.
- [64] Wang X, Wei J, Schuurmans D, et al. Self-consistency improves chain of thought reasoning in language models [C]. International Conference on Learning Representations, 2023.
- [65] Yao S, Yu D, Zhao J, et al. Tree of thoughts: deliberate problem solving with large language models [C]. Advances in neural information processing systems, 36, 2024: 11809–11822.
- [66] Tang X, Gu Y, Zhu Y, et al. Struc-Bench: are large language models really good at generating complex structured data? [J]. arXiv preprint arXiv:230908963, 2024.
- [67] Qin Y, Liang S, Ye Y, et al. Tool learning with foundation models [J]. arXiv preprint arXiv:230408354, 2024.
- [68] Schick T, Dwivedi-Yu J, Dessì R, et al. Toolformer: language models can teach themselves to use tools [C]. Advances in neural information processing systems, 36, 2024: 68539–68551.
- [69] Patil S G, Zhang T, Wang X, et al. Gorilla: large language model connected with massive APIs [J]. arXiv preprint arXiv:230515334, 2023.
- [70] Yao S, Zhao J, Yu D, et al. ReAct: synergizing reasoning and acting in language models [C]. International Conference on Learning Representations, 2023.
- [71] Kim L, others. A survey on employing large language models for text-to-SQL tasks [J]. arXiv preprint arXiv:240715186, 2024.
- [72] 周祥生, 肖萍, 韩普. 大模型推理任务调度系统设计与优化研究 [J]. 信息通信技术, 2025, 19(3): 37–44.
- [73] Wu Q, Bansal G, Zhang J, et al. AutoGen: enabling next-gen LLM applications via multi-agent conversation [J]. arXiv preprint arXiv:230808155, 2023.
- [74] Hong S, Zhuge M, Chen J, et al. MetaGPT: meta programming for a multi-agent collaborative framework [J]. arXiv preprint arXiv:230800352, 2024.
- [75] Li G, Hammoud H A A K, Itani H, et al. CAMEL: communicative agents for “mind” exploration of large language model society [J]. Advances in neural information processing systems, 2024, 36: 51991–52008.

- [76] 郭先会, 张梦姣, 马军. 基于大语言模型的智能体构建综述 [J]. 通信技术, 2024, 57(9): 873–879.
- [77] 李轶夫. 基于生成式大模型的 ai 智能体技术及应用发展趋势 [J]. 信息通信技术, 2025, 19(3): 14–21.
- [78] Chen J, Xiao S, Zhang P, et al. BGE M3-embedding: multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation [J]. arXiv preprint arXiv:240203216, 2024.
- [79] Malkov Y A, Yashunin D A. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(4): 824–836.
- [80] TBD. Placeholder reference [J]. TBD, 2024.
- [81] TBD. Placeholder reference [J]. TBD, 2024.
- [82] Shinn N, Cassano F, Gopinath A, et al. Reflexion: language agents with verbal reinforcement learning [C]. Advances in neural information processing systems, 36, 2024: 8634–8652.
- [83] TBD. Placeholder reference for isft [J]. TBD, 2024.

附录 A

攻读硕士学位期间取得的研究成果

- 一、攻读硕士学位期间发表的论文及科研成果
- 二、参与科研项目/科研获奖等